

オペレーティングシステム

Ver. 0.0.0

徳山工業高等専門学校
情報電子工学科

Copyright © 2017 by
Dept. of Computer Science and Electronic Engineering,
Tokuyama College of Technology, JAPAN

本ドキュメントは CC-BY-SA 4.0 ライセンスによって許諾されています。

本ドキュメントは CC-BY-SA 3.0 de ライセンス, CC-BY-SA 4.0 ライセンスで許諾された著作物を含みます。

CC-BY-SA 3.0 de ライセンス全文は <https://creativecommons.org/licenses/by-sa/3.0/de/> で確認できます。

CC-BY-SA 4.0 ライセンス全文は <https://creativecommons.org/licenses/by-sa/4.0/deed.ja> で確認できます。

目次

第 1 章	オペレーティングシステムとは	1
1.1	オペレーティングシステムの役割	1
1.1.1	拡張マシンとしてのオペレーティングシステム	1
1.1.2	ハードウェア管理プログラムとしてのオペレーティングシステム	2
1.2	オペレーティングシステムの歴史	2
1.2.1	第 1 世代 (1945～1955, 真空管の時代)	2
1.2.2	第 2 世代 (1955～1965, トランジスタの時代)	3
1.2.3	第 3 世代 (1966～1980, IC とマルチプログラミングの時代)	4
1.2.4	第 4 世代 (1980～現代, PC の時代)	6
1.2.5	インターネット世代	9
第 2 章	前提知識	11
2.1	コンピュータのハードウェア構成	11
2.2	CPU の構成	12
2.3	最近のコンピュータの実際の構成	13
2.3.1	デスクトップ・パーソナルコンピュータ	13
2.3.2	サーバコンピュータ	14
2.4	オペレーティングシステムの構造	14
2.4.1	カーネルの構成	14
2.4.2	カーネルの動作概要	15
2.4.3	プロセスの構造	16
2.5	カーネルの構成方式	17
2.5.1	単層カーネル (モノリシック・カーネル)	17
2.5.2	マイクロカーネル (micro-kernel)	17
2.6	もう一つの仮想マシン	17
2.6.1	Type 2 ハイパーバイザ	18
2.6.2	Type 1 ハイパーバイザ	18
2.6.3	仮想アプライアンス	19
第 3 章	CPU の仮想化	21
3.1	時分割多重	21
3.2	プロセスの状態	21
3.2.1	基本的な三つの状態	22
3.2.2	状態遷移	22
3.3	プロセスの切換え	23
3.3.1	切換えの原因	23

3.3.2	切換え手順	23
3.3.3	切換えの例	24
3.4	PCB (Process Control Block)	26
3.4.1	PCB の内容	26
3.4.2	PCB リスト	26
3.5	CPU 仮想化の実例	27
3.5.1	TacOS の PCB	27
3.5.2	TacOS のメモリ配置	30
3.5.3	TacOS のプロセス切換えプログラム	31
3.6	スレッド (Thread)	33
3.6.1	スレッドの役割	33
3.6.2	スレッドの形式	34
3.6.3	スレッドプログラミング	35
参考文献		39

第 1 章

オペレーティングシステムとは

オペレーティングシステム (Operating System : OS) は, Windows, macOS, Linux, FreeBSD, Android, iOS 等である. 皆さんは, これらを使用した経験を持っているだろう. そして, これらが次のようなソフトウェアから構成されていることを何となく感じているのではないだろうか.

1. カーネル (OS の本体)
2. ライブラリ (プログラムが使用するサブルーチン, DLL)
3. ユーザインタフェース (GUI, CLI)
4. ユーティリティソフトウェア (ファイル操作, 時計, シェル, システム管理 ...)
5. プログラム開発環境 (エディタ, コンパイラ, アセンブラ, リンカ, インタプリタ)

広義では上に列挙した全て^{*1}がオペレーティングシステムの一部である. 逆に**狭義**では「カーネル」だけをオペレーティングシステムと考える. この講義では狭義のオペレーティングシステムの仕組みを勉強する.

1.1 オペレーティングシステムの役割

オペレーティングシステムの重要な役割は次に述べる二つである.

1.1.1 拡張マシンとしてのオペレーティングシステム

OS はハードウェアの機能を**抽象化**した便利な拡張マシンを提供する. 次に抽象化と拡張マシンの例を示す.

例 1 二次記憶装置の抽象化 (ファイルシステム)

ハードディスク, USB メモリ, CD-ROM 等の二次記憶装置は, どれもデータを記録する機能を持ったハードウェアである. しかし, それらの制御方法や記録されるデータの構造は全く異なる. オペレーティングシステムは, 二次記憶装置をファイルの集合 (ファイルシステム) として**抽象化**してユーザプログラム (アプリケーションプログラム) に提供する.

例 2 コンピュータそのものの抽象化 (プロセス)

プロセスはプロセス専用の仮想 CPU と仮想メモリを持つ. システムコールを通じて入出力も可能である. プロセスは CPU, メモリ, 入出力を持っているので 1 台のコンピュータと考えることもできる.

プロセスはコンピュータを**抽象化**したものだとも言える. (プロセス=仮想コンピュータ)

例 3 拡張されたコンピュータ (システムコール)

オペレーティングシステムを備えたコンピュータ上では, アプリケーションプログラムがシステムコールを発行できる. システムコールを追加命令を考えると, オペレーティングシステムを備えたコンピュータは追加命令を実行可能な**拡張マシン**だと言える. (拡張マシンの命令=機械語命令+システムコール)

オペレーティングシステムが拡張マシンをアプリケーションプログラムに提供するイメージを図 1.1 に示す. ハードウェアの複雑で統一されていない凸凹のインタフェースは, オペレーティングシステムによってスッキリし

^{*1} 上に挙げたソフトウェアの中で「プログラム開発環境」は, Linux や FreeBSD では OS に含まれているが, それ以外では別にインストールする必要がある OS の一部とは言い難くなっている.

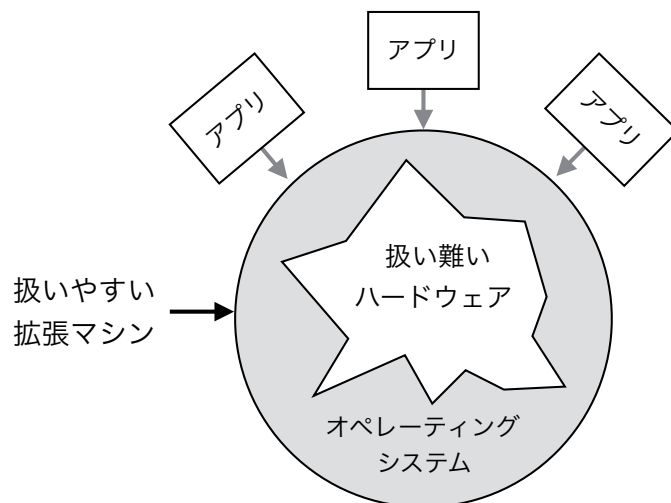


図 1.1 抽象化

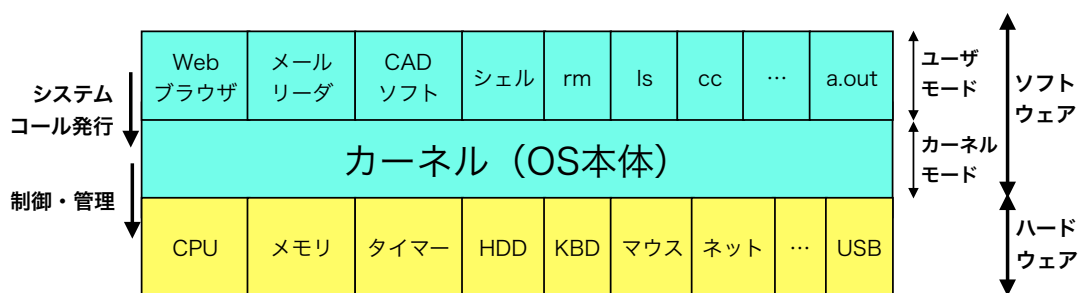


図 1.2 コンピュータシステムの構成

た円弧のインタフェース（使いやすい**抽象化**されたインタフェース）に変換される。

オペレーティングシステムの円がハードウェアの外側にあるのは、オペレーティングシステムによって機能が拡張されたことを示す。ハードウェアを含む円全体が拡張マシンを表している。

1.1.2 ハードウェア管理プログラムとしてのオペレーティングシステム

オペレーティングシステムはハードウェア資源を管理・制御し、アプリケーションプログラムにシステムコール等のサービスを提供する。図 1.2 はカーネルの役割を説明している。

オペレーティングシステムは管理するハードウェア資源をアプリケーションプログラムに割当てる。複数のアプリケーションプログラムに割り付けるために資源は必要な数だけ**仮想化**して準備する必要がある。例えば、CPU は時間を区切って複数のプロセスが共有する（時分割多重による**仮想化**）。メモリはアドレスで区切って複数のプロセスが共有する（空間分割多重による**仮想化**）。

1.2 オペレーティングシステムの歴史

1.2.1 第1世代（1945～1955、真空管の時代）

初期のコンピュータはコンソールパネルを通して操作する、巨大な TeC のようなものだった。OS は存在せずプログラマはまさに TeC と同様なプログラミングとデバッグを行っていた。

しかし、当時のコンピュータは TeC と異なり大変高価な装置であった。その高価なコンピュータを一人のプログラマが長時間にわたって独占使用することになる。プログラマがバグの原因を考えている間、とても高価なコン

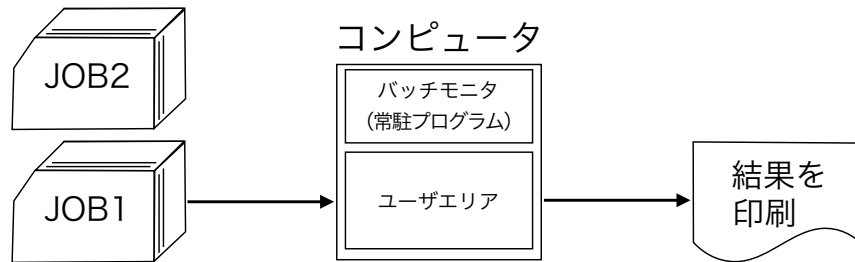


図 1.3 バッチ処理

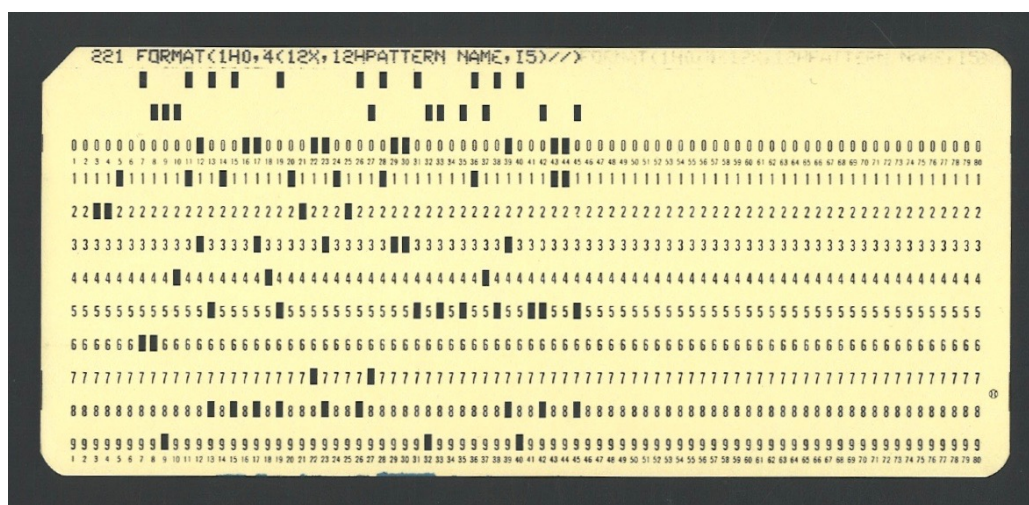


図 1.4 紙カード

ピュータが遊んでしまい勿体ないものであった。

1.2.2 第2世代（1955～1965、トランジスタの時代）

トランジスタ回路で製作されるようになり、**メインフレーム**と呼ばれる大型コンピュータが大企業、政府機関や大学等で実用的に使用されるようになった。メインフレームは数百万ドルと高価だったので、ハードウェアを遊ばせること無く使用することが優先課題であった。そこで人手を介すること無く自動的に次々と連続して処理を行う「コンピュータの自動運転」が行われるようになった。この処理方式のことはバッチ処理と呼ばれた。図 1.3 にバッチ処理の概要を示す。

プログラマは図 1.4 のような紙カードにプログラムやデータを一行ずつ打込む。100 行のプログラムは 100 枚の紙カードを使用して記録する。このようにして出来た紙カードの束が一つの処理を単位（ジョブ）になる。コンピュータでは**バッチモニタ**と呼ばれる常駐プログラムが実行される。バッチモニタは紙カードからジョブを読み込み実行させる。ジョブが終了するとバッチモニタに制御が戻り次のジョブが自動的に実行される。バッチモニタが発展してやがて OS になる。

この方式でうまく処理できるように次のような発明があった。

1. JOB 制御言語（JCL : Job Control Language）

バッチモニタを制御するコマンド言語を JOB 制御言語（JCL）と呼ぶ。JCL コマンドはジョブ途中の紙カードに記載する。図 1.5 に JCL を含むジョブの構成を示す。これは、FORTRAN 言語で記述したプログラムを実行し、後半にあるデータを処理するジョブの例になっている。

2. 実行モード




図 1.5 ジョブの構成

ユーザプログラム（ジョブ）のバグでバッチモニタが破壊されないようにするために、ユーザプログラム実行中なのかバッチモニタ実行中なのかを区別する必要がある。どちらを実行中なのかを示すハードウェアのフラグを導入し、ユーザモードとカーネルモード（スーパーバイザモードとも呼ぶ）を区別するようになった。ユーザモードではハードウェアへのアクセスや、実行できる機械語命令に制限がある。

3. システムコール

ユーザプログラムが直接に入出力装置等にアクセスすることは、バッチ処理を継続できなくなる恐れがあるので許されない。例えばユーザプログラムがハードウェアのモードを切り換えてしまうと、以降のジョブが正常に実行されなくなる。そこで、ユーザプログラムはバッチモニタに依頼（システムコール）して入出力を行う必要がある。

プログラムが終了する時はカーネルモードに切り換えてバッチモニタに戻る必要がある。カーネルモードに切り替える機械語命令をユーザプログラムが実行可能だと、実行モードが無意味になるので許可すべきではない。システムコールを使用してプログラムを終了する。

4. 記憶保護

ユーザプログラムのバグでバッチモニタが破壊されないように、ユーザモードで実行中は主記憶のバッチモニタ領域に書き込みができないようにする。

1.2.3 第3世代（1966～1980, IC とマルチプログラミングの時代）

1960年代のコンピュータはIC（Integrated Circuit）を用いて作られるようになり価格性能比が随分改善された。第3世代と呼ばれる当時のオペレーティングシステムの中には、現代のオペレーティングシステムの先祖であったり、強い影響を与えたものがある。図 1.13 に第3世代から現代に至るまでの系統図を示す。

IBMが開発したSystem/360（図 1.6）は高価な大型のものから、安価な小型のものまでで同じオペレーティングシステムが使用でき、同じユーザプログラムを実行できる**シリーズ化**を行い商業的に大成功をおさめた [27]。System/360はそれ以前のものとは異なり科学技術計算にも事務処理にも使用できる。System/360のオペレーティングシステムは、1966年にデビューしたOS/360である。図 1.13 に示すように、OS/360の子孫であるz/OSが現代でも使用されている [1]。

OS/360を含む第3世代のオペレーティングシステムが実現した重要な新しい機能を紹介する。

- 仮想記憶

主記憶を仮想化し実際より大きい主記憶があるように見せる。実際の主記憶より大きいプログラムが実行可能になる。

- マルチプログラミング

図 1.7 のように、複数のプログラム（ジョブ）を主記憶にロードしておき、その中で実行可能なものを選んで実行する。入出力待ち等で実行できなくなったら他のプログラムを実行する。高価なCPUが入出力待ちで停止する可能性を低くすることができた。

- タイムシェアリング



ウィキメディア / Bundesarchiv, B 145 Bild-F038812-0014 / Schaack, Lothar / CC-BY-SA 3.0 de

図 1.6 フォルクスワーゲンで使われている System/360




図 1.7 マルチプログラミングシステム




図 1.8 タイムシェアリングシステム

マルチプログラミングの一種である。図 1.8 のように、複数のターミナルをコンピュータに接続し複数のユーザが同時にコンピュータを使用できるようにする。短時間（例えば 10ms）で処理するジョブを次々に切り換えることで、ユーザは自分がコンピュータを独占しているように感じることができる。なお、ターミナルは図 1.9 のような、キーボードと表示装置だけを備えた安価な装置である。

この時代のオペレーティングシステムやコンピュータシステム、そして、それらの開発プロジェクトの中で、その後のオペレーティングシステムに多くの影響を与えた有名なものを紹介する。



写真：<http://commons.wikimedia.org/wiki/File:Televideo925Terminal.jpg> (パブリックドメイン)

図 1.9 ターミナル

- OS/360
世界初の本格的な商用オペレーティングシステムである。メインフレームの主流 OS となり子孫は現在でも使用されている [1].
- MULTICS (MULTiplexed Information and Computing Service) プロジェクト [27]
MIT, ベル研究所, General Electric が共同で始めた巨大で強力なコンピュータシステムを構築するプロジェクトである。強力な一台のコンピュータで都市一つ分のコンピュータサービスを提供する構想だった。完成までに長い期間を要し（その間にベルと GE が脱離し）、商業的には失敗であったがその後のオペレーティングシステムに影響を与える多くのアイデアが出てきた。
- UNIX (ユニックス)
MULTICS プロジェクトから抜けたベル研の Ken Thompson らにより開発された [5]。図 1.13 に示すように、現代のオペレーティングシステムの多くが UNIX を起原にしている。子孫ではないものも UNIX の影響を強く受けている。Linux は UNIX 互換のオペレーティングシステムを作ろうとして開発が始まった [19]。Android の中身は LINUX である [20]。z/OS は UNIX 互換環境を備えている [4]。Windows にも UNIX 互換環境 (POSIX サブシステム) を利用可能なものがある [22]。
- DynaBook (ダイナブック：OS だけでなくコンピュータ全体を指す) [31]
アラン・ケイが 1972 年に著した「A Personal Computer for Children of All Ages」[29, 30] に登場する理想のパーソナルコンピュータである。アラン・ケイがゼロックスのパロアルト研究所に在籍中の 1970 年代に開発した Alto 上の「暫定ダイナブック環境」(図 1.10) は既に GUI やマウスを使用していた。スティーブ・ジョブズが Alto を見たことが LISA 開発きっかけになったと言われている [16]。

1.2.4 第4世代 (1980～現代, PC の時代)

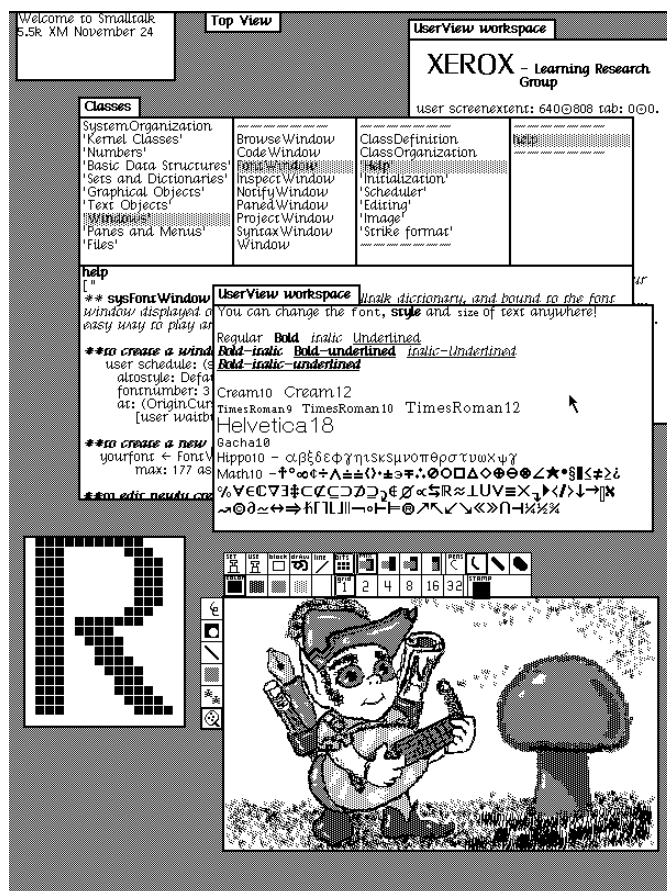
1970 年代に単一の LSI に CPU 全体を集積したマイクロプロセッサが登場した。1970 年代中旬にはマイクロプロセッサを用いて個人向けのコンピュータであるパーソナルコンピュータ（当時はマイクロコンピュータと呼んでいた）を作ることが可能になった。それに伴いパーソナルコンピュータ用のオペレーティングシステムが登場した。

1. 8bit マイクロコンピュータの時代

1977 年に Digital Research 社が CP/M (Control Program for Microcomputer) と呼ばれる 8bit マイクロコンピュータ用の簡単なオペレーティングシステムを開発し成功した。しかしこのオペレーティングは 16bit パーソナルコンピュータの時代には早々に消え去ってしまった [28]。

2. 16bit パーソナルコンピュータの時代

IBM が 1981 年に 16bit パーソナルコンピュータ IBM PC [23] (図 1.11) を発売した。IBM PC は現在の



ウィキメディア / SUMIM.ST /

Alto や NoteTaker で動作したアラン・ケイ達の暫定 Dynabook 環境 (Smalltalk-76、同-78 の頃) / CC-BY-SA

4.0

図 1.10 Alto (Alto エミュレータ) のスクリーンショット

Windows PC の先祖である、IBM PC の子孫は改良や拡張を続けながら現在まで高いシェアを維持し続けている。IBM PC のオペレーティングシステムとして開発されたのが、Microsoft 社の MS-DOS (MicroSoft Disk Operating System) [21] である。バージョン 2 からは UNIX のような階層ディレクトリやパイプ、リダイレクト等の機能を持っている。図 1.13 に示すように、MS-DOS は Windows に置き換わり Windows ME までバージョンアップが繰り返された。

Apple 社は 1984 年に Macintosh (図 1.12) を発売した。Macintosh の OS である MacOS は LISA を経て DynaBook[29, 30] の影響を受けていると言われている [28]。図 1.13 に示すように、当初の MacOS は MacOS 9[15] まで改良が続けられた。

3. 32bit パーソナルコンピュータの時代

1990 年頃には 32bit のマイクロプロセッサがパーソナルコンピュータにも使用されるようになった。32bit のマイクロプロセッサは実行モードを備え、またメモリ管理ユニットも利用可能であった。つまり、カーネルモードとユーザモードを使い分けたり仮想記憶を利用する本格的な第 3 世代のオペレーティングシステムを実行できる環境がパーソナルコンピュータにも整った。

そこで、従来ワークステーションやミニコンで使用されていた UNIX を安価なパーソナルコンピュータ (特に IBM PC 互換機) で動くようにする人たちが現れ、オープンソースソフトウェアとして LINUX や FreeBSD 等の開発が始まった。また、もともとパーソナルコンピュータ用の Windows や Mac OS も 32bit マイクロ



ウィキメディア / Bundesarchiv, B 145 Bild-F077948-0006 / Engelbert Reineke / CC-BY-SA 3.0 de

図 1.11 IBM PC



ウィキメディア / w:User:Grm wnr / File:Macintosh 128k transparency.png /GFDL

図 1.12 初代 Macintosh

プロセッサの機能を使いこなす本格的なオペレーティングシステムに生まれ変わった。

- LINUX

1991 年に開発が始まった LINUX は UNIX 互換のオペレーティングシステムをパーソナルコンピュータ (IBM PC 互換機) 用に独自に作成したものである [19]。LINUX は改良され続け、現在ではパーソナルコンピュータだけでなく、スーパーコンピュータ「京」のオペレーティングシステム [32] から、スマートフォンのオペレーティングシステムである Android[20]、テレビ等の組み込みシステムのオペレーティングシステムまで、広く使われるようになっている。

- BSD 系の UNIX

386BSD[11] は BSD UNIX を Intel 80386 CPU を搭載したパーソナルコンピュータ (IBM PC 互換機) で動作するようにしたものである。386BSD は FreeBSD 等に受継がれるが UNIX のライセンス問題が発生する [5]。ライセンス問題が片付き安心して使用できるようになった 4.4BSD-Lite Release 2[5] をベースに FreeBSD, NetBSD, OpenBSD 等の多くの BSD 系 PC-UNIX が開発された。

その後、FreeBSD は MacOS X に取り込まれている。また、FreeBSD に ZFS が移植された [33] のでファイルサーバ用に特化した FreeNAS[13] にも使用されている。なお、徳山工業高等専門学校・情報電子工学科のパソコン室では 1993 年 10 月に 386BSD の利用を開始して以来、2014 年 3 月まで FreeBSD を学生用 PC やサーバのオペレーティングシステムとして使用してきた [25]。

- System V 系の UNIX

System V の流れを汲む Solaris[6] は、RISC マイクロプロセッサ SPARC を搭載するサーバやワークステーションでも、パーソナルコンピュータ (IBM PC 互換) でも使用できる。

- 従来のパーソナルコンピュータ用オペレーティングシステム

従来の Windows や Mac OS は CPU の実行モード等を使用していなかったため、アプリケーションプログラムのバグによりシステム全体が停止するようなトラブルを防ぐことができなかった。そこで、32bit マイクロプロセッサの使用を前提に新しく作り直された。

新しく作り直された 32bit の Windows NT 系列の製品は、徐々に従来の Windows を置換えた。(図 1.13 参照)。現在 (2017 年 10 月) の最新版は Windows 10 である。

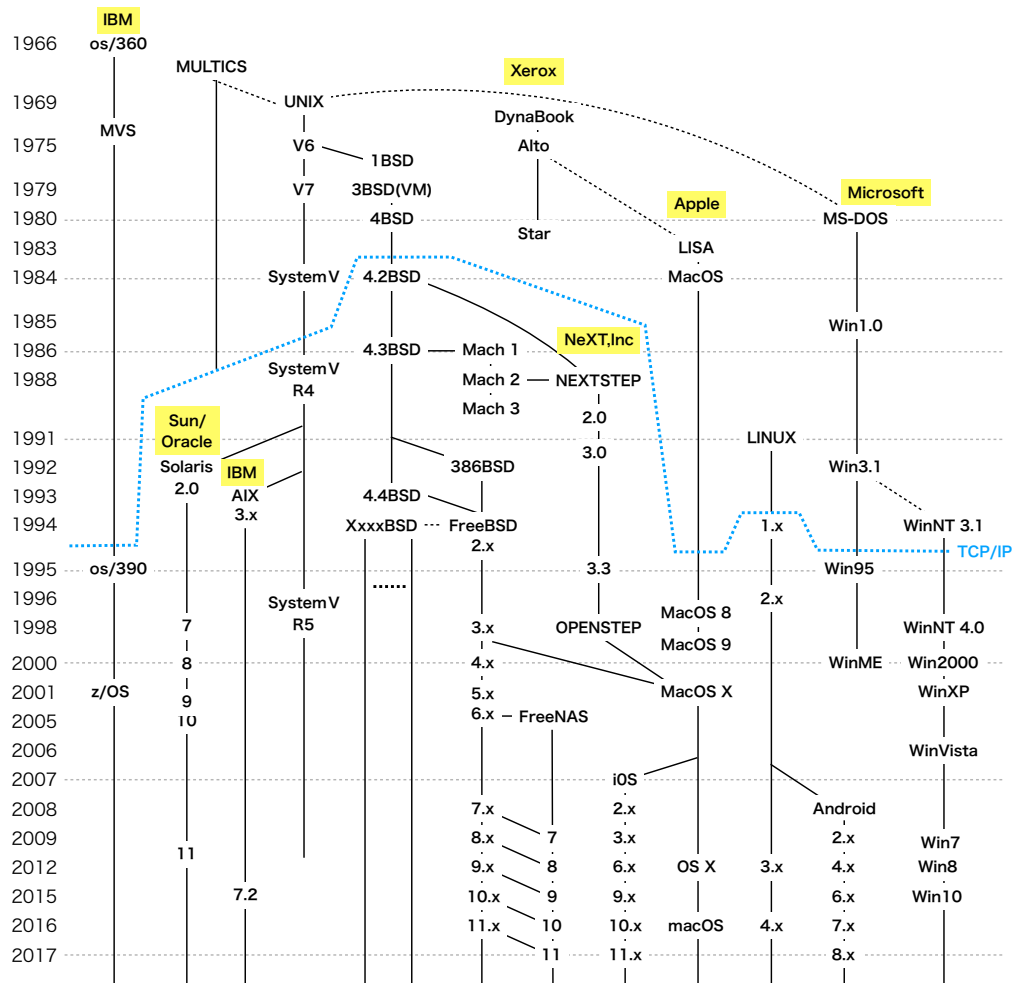
MacOS は、2001 年に UNIX の流れを汲み安定して動作する OPENSTEP ベースの MacOS X[17] に置き換わった (図 1.13 参照)。その後、名称が OS X、macOS と変更されたがこれらは MacOS X の改良版である。現在 (2017 年 10 月) の最新版は macOS 10.13 High Sierra である。iPhone の iOS は MacOS X をタッチパネル用に再構成したものである [18]。

1.2.5 インターネット世代

現在のオペレーティングシステムは TCP/IP 機構が組み込まれインターネットに接続することができる。今ではパーソナルコンピュータやスマートフォンの使用をインターネット抜きに考えることができない。オペレーティングシステムにとってインターネットに接続できることは重要なことである。

TCP/IP を実装した 4.2BSD が 1984 年に公開された [10]。以来、4.2BSD の子孫はインターネットに対応している。1988 年に公開された System V R4 は BSD 起原の TCP/IP の実装を含んでいた [24]。これの子孫もインターネットに対応している。LINUX も 1.0 の頃には TCP/IP の実装を含んでいた [26]。Windows は Windows 95 から TCP/IP を標準装備している [22]。MacOS は MacOS 8 が発表されるまでにはインターネット対応がされていた [15]。メインフレームの世界でも OS/390 はインターネットに対応した [3]。

このようにして 1990 年代の後半には多くのオペレーティングシステムがインターネット対応を完了させた。インターネット対応を完了させたオペレーティングシステムを「インターネット世代のオペレーティングシステム」と言うことができる。



系統図は [1, 2, 3, 4, 5, 6, 7, 8, 10, 9, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22] の内容を総合して作成した。

図 1.13 オペレーティングシステムの系統図

第 2 章

前提知識

以下では、本書で想定しているコンピュータのハードウェアやソフトウェアの構成について解説する。

2.1 コンピュータのハードウェア構成

本書は、コンピュータのハードウェア構成が図 2.1 のようになっていることを前提にしている。複数の CPU (Central Processing Unit) がメモリを共有し、また、全ての CPU は同じ機能を持ち優劣が無い。このような方式を SMP (対称型マルチプロセッシング: Symmetric Multiprocessing) と呼ぶ。メモリは CPU だけでなく、I/O コントローラ (図 2.1 ではアダプタやコントローラ) にも共有される。

1. CPU

CPU はコンピュータの頭脳である。図は CPU が二つの構成になっているが、実際は一つの場合も、もっと多い場合もある。

2. メモリ (主記憶装置)

プログラムやデータを記憶し、プログラム実行する際に CPU が直接使用する記憶装置である。

3. タイマー

一定間隔で繰り返し CPU に割り込みを発生するインターバルタイマーである。

4. グラフィックアダプタ

ディスプレイを接続するためのアダプタである。表示内容を記憶するメモリを独自に持つ場合と、主記憶装

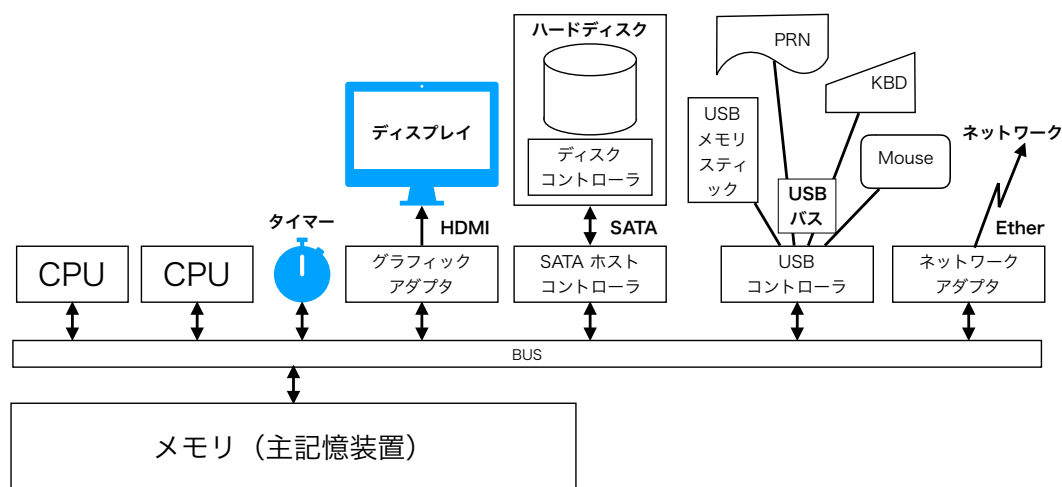


図 2.1 ハードウェア構成

置を使用する場合がある。最近のパーソナルコンピュータでは、グラフィックアダプタに GPU(Graphics Processing Unit) が組込まれている。

5. SATA ホストコントローラ

SATA (Serial Advanced Technology Attachment) は、パーソナルコンピュータと二次記憶装置 (ハードディスクや CD-ROM) を接続するためのインタフェース規格である。SATA ホストコントローラは次のような動作をする。

- (a) CPU がコマンドを SATA ホストコントローラに書き込む。コマンドは、「読み／書き」、「セクタアドレス」、「セクタ数」、「メモリアドレス」を含んだものである。
- (b) SATA ホストコントローラは、ディスクコントローラと通信しハードディスクにコマンドを渡す。
- (c) ハードディスクの読み・書きが可能になったら、ホストコントローラはハードディスクとメモリの間でデータ転送を行う。このような CPU を介さないデータ転送のことを、**DMA (Direct Memory Access)** と呼ぶ。
- (d) SATA ホストコントローラは CPU に割り込み信号を送り、データの転送が完了したことを知らせる。(完了割り込み)

CPU は、SATA ホストコントローラにコマンドを送ってから割り込みが発生するまでの間、他の仕事を行うことができる。ハードディスクの操作 (I/O 操作) と CPU の計算は並列実行される。

6. USB コントローラ

USB (Universal Serial Bus) は、パーソナルコンピュータと周辺装置を手軽に接続できるインタフェースである。USB メモリスティックやプリンタ、キーボード、マウス等、多くの周辺装置が USB を通して接続できる。USB コントローラも SATA ホストコントローラのように DMA 機能を備えている。

7. ネットワークアダプタ

パーソナルコンピュータのネットワークアダプタは、GbE (Gigabit Ethernet) 規格のものが普及している。これも SATA ホストコントローラのように DMA 機能を備えている。

8. BUS (バス)

パーソナルコンピュータのハードウェアを構成する装置の間でデータをやり取りするための配線である。CPU だけでなく DMA を使用するコントローラやアダプタが大量のデータ転送を行うので、バスのデータ転送能力がパーソナルコンピュータの性能向上のボトルネックになる。

そのため後で説明するように、実際の物理的な接続は図 2.1 とはかなり異なった構成になっている。しかし、オペレーティングシステムが意識しなければならない論理的な接続は図 2.1 のようなものである。

2.2 CPU の構成

本書では、CPU は図 2.2 のような部品で構成されると考える。図 2.1 に示したように、CPU は BUS を通して他の装置と接続される。CPU は、他の装置から割り込みを受け付けることができる。

1. PSW (Program Status Word)

PSW は、PC (Program Counter) と Flags (フラグ) から構成されるものとする^{*1}。PC は CPU が実行中のプログラムの命令アドレスを保持するカウンタである。Flags は計算の結果によって変化するフラグの他に、割り込み許可／不許可を表現するビット、実行モード (ユーザモード／カーネルモード) を表現するビット等が含まれる。

2. CPU レジスタ

計算に使用する CPU の汎用レジスタのことである。TeC では G0, G1, G2, SP のこと、情報処理技術者試験の COMET では GR0, GR1, GR2, GR3, GR4 のことである。

PSW と CPU レジスタは、プログラムがプログラムから見える^{*2}ので、CPU を仮想化し実行するプロセスを切替える際に保存・復旧の対象となる。

^{*1} 教科書によっては、フラグだけを PSW と呼ぶ場合もある。

^{*2} これらはプログラムが意識しているレジスタ等である。一方で CPU 内部にはプログラムから見えないレジスタもある。




図 2.2 CPU の構成

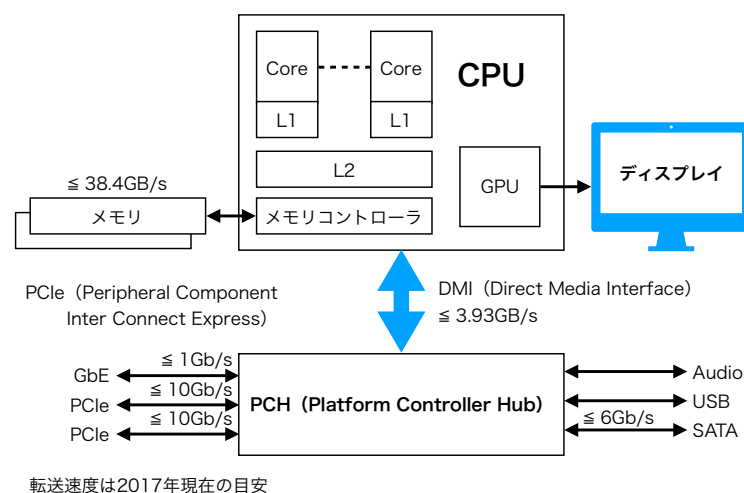


図 2.3 デスクトップ PC の構成

2.3 最近のコンピュータの実際の構成

Intel 社の CPU を使用したデスクトップ・パーソナルコンピュータとサーバコンピュータの構成を説明する。バスがボトルネックにならないように、メモリを CPU に直接接続してある。

2.3.1 デスクトップ・パーソナルコンピュータ

図 2.3 は Intel 社の CPU を使用した近年のデスクトップ・パーソナルコンピュータの構成を表している。Intel 社の用語では、これまで「CPU」と読んでいたものが「Core (コア)」と呼ばれる。「CPU」は複数のコアを含んだ LSI のことを指している。デスクトップ用の CPU には 1～4 個のコアが集積されている。

コアに隣接している L1 はレベル 1 キャッシュ (Level 1 cache) を表している。L2 は複数のコアにシェアされるレベル 2 キャッシュ (Level 2 cache) を表している。メモリとのデータ転送量が多い Core と GPU が CPU に集積され、I/O 装置のコントローラやアダプタは PCH に集積されている。CPU と PCH は DMI と呼ばれる専用のインタフェースを用いて接続される。

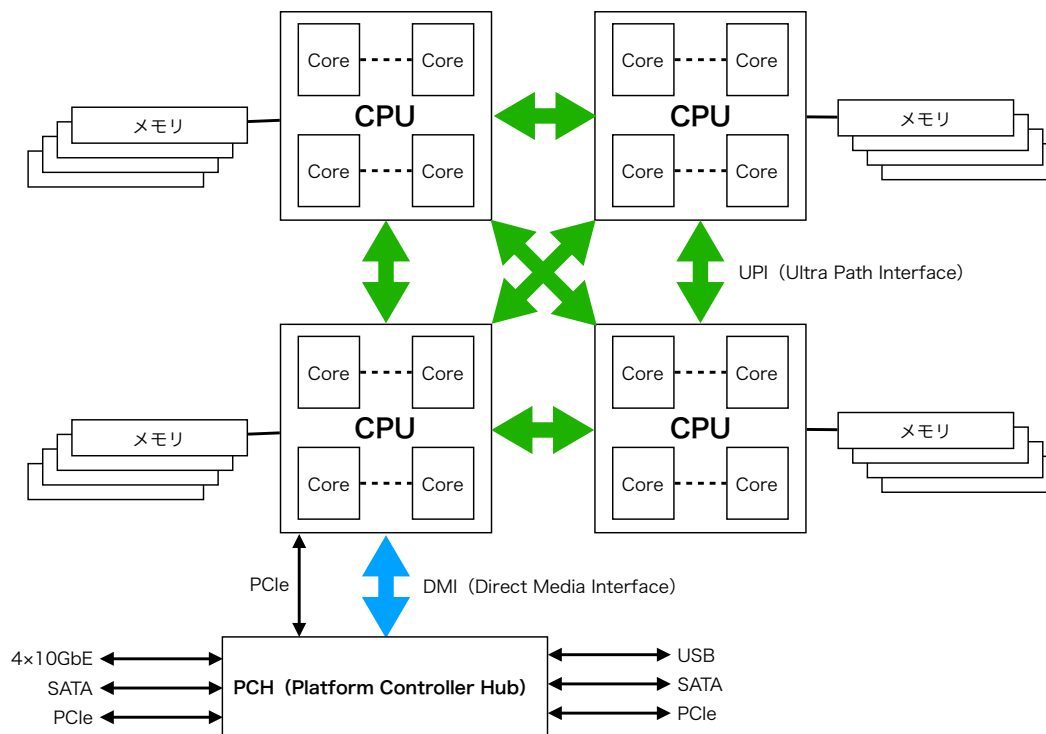


図 2.4 サーバ PC の構成

2.3.2 サーバコンピュータ

より強力な処理能力が必要なサーバ用コンピュータでは、図 2.4 のように多くのコアを内蔵する CPU を複数個使用する。現在（2017 年秋）最新の Intel Xeon Processor Scalable Family の場合、CPU 同士は UPI と呼ばれる高速な専用インタフェースで接続される。最大の構成は、28 コアの CPU を 8 個使用し合計 224 コアのものである。PCH もサーバ用のものでは、より多くのストレージやネットワークを接続できる。

2.4 オペレーティングシステムの構造

図 2.5 にオペレーティングシステムの構造を示す。オペレーティングシステムのカーネルは図 2.5 中央部分のソフトウェアである。ユーザプロセスはユーザモードで、カーネルはカーネルモードで実行される。

2.4.1 カーネルの構成

図 2.5 に示すように、カーネルは以下のようなモジュールから構成される。

1. 割り込みハンドラ

割り込みが発生した時に自動的に実行される割り込み処理ルーチンである。割り込みが発生した原因を判断し、必要なモジュールを呼出す。例えば、タイマーからの割り込みならタイマーのデバイスドライバを呼出す。

2. ディスパッチャ

カーネルの処理が終了した時、実行可能なプロセスの中から一つを選んで実行を再開させる。

3. コア

割り込みハンドラとディスパッチャを含むコアは、資源の仮想化を行うために必ずカーネルモードで実行される必要がある部分である。

4. サービスモジュール

サービスモジュールは、ハードウェアを抽象化した便利なコンピュータをユーザ・プロセスに提供するためのプログラムである。

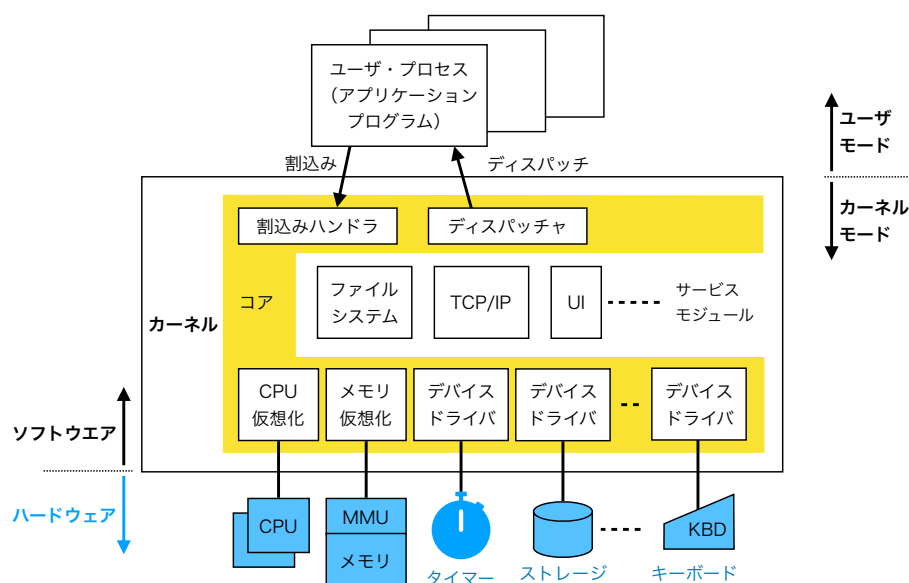


図 2.5 オペレーティングシステムの構造

2.4.2 カーネルの動作概要

通常、コンピュータはユーザ・プロセスを実行し目的の仕事をしている。何かイベントが発生すると割込みにより CPU に通知される。CPU はカーネルモードに切り替わり割込みハンドラに制御を移す。CPU がユーザ・プロセスの実行からカーネルの実行に移行するのは、**割込みが発生した時だけ**である。

割込み原因

カーネルへ実行を移すには割込みを発生する以外に方法がない。割込みが発生する原因には以下のようなものがある。システムコール以外はユーザ・プロセスが意図しない間に発生する。

1. I/O 完了・タイマー
ホストコントローラやネットワークアダプタ、タイマーのようなハードウェアが、コマンドの実行完了等を CPU に知らせるために発生する。
2. システムコール
ユーザ・プロセスは、割込みを発生する特殊な機械語命令である SVC (Supervisor Call) 命令を用いてシステムコールを発行する^{*3}。カーネルは SVC 命令実行時の CPU レジスタの値などによりシステムコールの種類やパラメータを知ることができる。
3. 保護違反
ユーザ・プロセスが、ユーザ・モードでは実行が許可されない命令を実行したり、アクセスが許可されないメモリ領域をアクセスした場合に発生する。
4. ソフトウェアのエラー
ユーザ・プロセス実行中に計算でオーバーフローが発生したような時に発生する。
5. ハードウェアのエラー
ハードウェアの故障や電源の異常を検知した時に発生する。

割込み発生時のカーネルの動作

割込みが発生するとカーネル・モードに切り換わり割込みハンドラに制御が移る。その後、カーネル内では以下のような手順で処理がされる。

^{*3} CPU によっては TRAP 命令、INT 命令と呼ばれることもある。

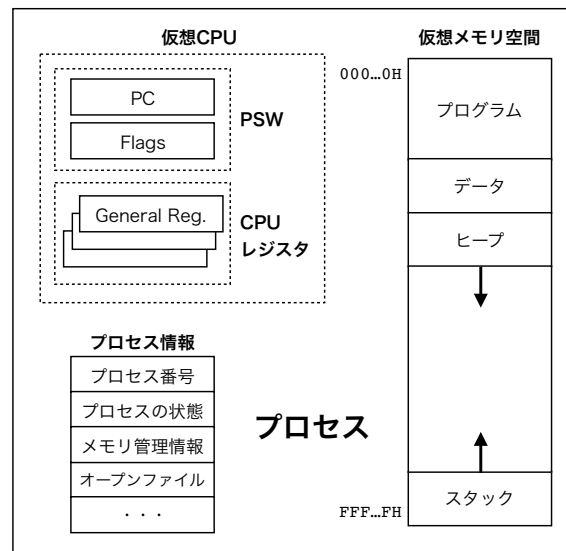


図 2.6 プロセスの構造

1. 割込みハンドラは後でプロセスの実行を再開できるように、プロセスの CPU の状態（コンテキスト：PSW，CPU レジスタ）を保存する。
2. 割込みハンドラは割込み原因を調べ、原因に応じたカーネル内のサービスモジュールやデバイスドライバに制御を渡す。例えばファイル操作のシステムコールならファイルシステムへ制御を渡す。
3. サービスモジュールやデバイスドライバの処理が終了したらディスパッチャに制御が渡される。ディスパッチャは実行可能なプロセスの一つを選び、コンテキストを復旧しプロセスの実行を再開させる。

2.4.3 プロセスの構造

図 2.5 のユーザ・プロセス部分を詳しく描いたものを図 2.6 に示す。プロセスを構成する各部を以下で説明する。

1. 仮想 CPU

CPU を仮想化し、プロセス毎に CPU が存在するように見せることで、マルチプログラミングを可能にする。プロセスが CPU を使用する時間を区切り、次々に切替える時分割多重により CPU の仮想化は達成される。他のプロセスが CPU を使用している間に、プロセスのコンテキストを保存する領域を仮想 CPU と呼ぶことにする。ハードウェアの実 CPU に対応して PSW と CPU レジスタの保存先が必要である。前の節で説明したように、プロセスからカーネルに制御が移る時にプロセスのコンテキストを保存する。プロセス実行時にはコンテキストが実 CPU にロードされる。

2. 仮想メモリ空間

メモリを仮想化しプロセス毎に専用のメモリ空間が存在するように見せかける。実現方法は第 7 章の「メモリ管理」で詳しく学ぶ。仮想メモリ空間は次の部分から構成される。

(a) プログラム

機械語プログラムがここに配置される。C 言語では関数の実行文（式文，if 文，for 文，while 文など）が翻訳された機械語が該当する。

(b) データ

プログラムの変数部分がここに配置される。C 言語ではグローバル変数が該当する。

(c) ヒープ

プログラム実行時に動的に拡大される領域である。C 言語の `malloc()` 関数はヒープに新しい領域を確保する。`malloc()` 関数が使用される度にヒープ領域は後ろに向かって拡大していく。

(d) スタック

プログラム実行時にメモリ空間の最後から前に向かって伸びて行く領域である。サブルーチン・コール時に戻りアドレスを保存したり、C 言語のローカル変数や関数引数を置いたりするために使用される。

3. プロセス情報

名前にあたる「プロセス番号」、実行中／実行可能／待ちのどの状態なのかを表す「プロセスの状態」、使用しているメモリの大きさ等を表す「メモリ管理情報」、CPU を使用した時間を表す「CPU 時間」等の情報のことである^{*4}。その他に、プロセスが現在オープンしているファイルに関する情報や、親プロセス、子プロセス、シグナルハンドラの登録状況、プロセスの優先度など、様々な情報がここに記録される。

2.5 カーネルの構成方式

カーネルが動作不良を起こすと、実行中の全てのユーザ・プロセスを巻き込んでシステムが停止したりするので、カーネルには非常に高い信頼性が要求される。しかし、カーネルは非常に大きなプログラムになりがちであり^{*5}、高い信頼性を確保するにはカーネルの構成方法に工夫が必要である。

2.5.1 単層カーネル（モノリシック・カーネル）

最も一般的な構成方法である。図 2.5 のカーネルは単層カーネルの例になっている。カーネル内の全てのモジュールがリンクされ、一つのプログラムになる。カーネル内でモジュールの呼出しは CALL 機械語命令を用いて行うので効率が良い。しかし、モジュール同士が密にリンクされているので、モジュール間で情報の隠蔽が難しくバグが入りやすい。また、全てのモジュールがカーネル・モード実行されるので、一つのモジュールのバグが致命的な結果を引き起こす。Linux や FreeBSD は、この方式のカーネルを持つ。

2.5.2 マイクロカーネル（micro-kernel）

図 2.5 の「コア」からデバイスドライバを取り除き^{*6}、カーネル（マイクロカーネル）とし構成する方式である。図 2.7 にマイクロカーネル方式の概要を示す。カーネル・モードで実行されるのはマイクロカーネルだけである。

サービスモジュールはカーネルから独立したサーバ・プロセスとし、権限の低いユーザ・モードで実行される。ユーザ・プロセスは、マイクロカーネルが提供する IPC（プロセス間通信：Inter-Process Communication）を用いて、サーバ・プロセスにサービスを要求する。サーバ・プロセス同士、サーバ・プロセスとデバイスドライバ・プロセスも IPC を用いて通信する。

デバイスドライバは I/O ポートにアクセスするのでカーネル・モードで実行される必要があると考えられるが、I/O ポートへのアクセスをマイクロカーネルのシステムコールに置換えることで、デバイスドライバもユーザ・プロセスとして実装することが可能である。この場合は、デバイスドライバがアクセスしても良い I/O アドレスの範囲内かどうか、マイクロカーネルがチェックすることが可能である。

マイクロカーネル方式は、サービスモジュールやデバイスドライバが権限の低いプロセスとして実行されるので、これらのバグでシステム全体が停止する危険が低い。また、サービスモジュールやデバイスドライバ毎に独立したプログラムになりモジュール化が徹底しやすいので、巨大な単一プログラムであるモノリシックカーネルと比較してバグが発生しにくい。信頼性の高いオペレーティングシステムを構成するために有利である。しかし、IPC とプロセス切り換えのオーバーヘッドが大きいため性能が低くなる。多くの場合、信頼性と性能はトレードオフの関係にある。

2.6 もう一つの仮想マシン

1.1 で述べたように、オペレーティングシステムは抽象化され便利な拡張マシン（仮想マシン）を、必要な数だけ提供する。ここで述べた仮想マシンは、単一ユーザ・プロセスの実行環境のことである。同じ「仮想マシン」と言う用語が、オペレーティングシステムを実行することが可能な、よりハードウェアを忠実に再現した仮想マシンを指す場合もある。ここでは、一台のコンピュータ上で複数のオペレーティングシステムを実行可能なもう一つの

^{*4} これらは UNIX の ps コマンドで表示することができる。

^{*5} Linux や Windows のカーネルのソースコードは 500 万行にもなる [34]。

^{*6} タイマーのデバイスドライバは CPU の仮想化に必要なので、マイクロカーネルに残す。

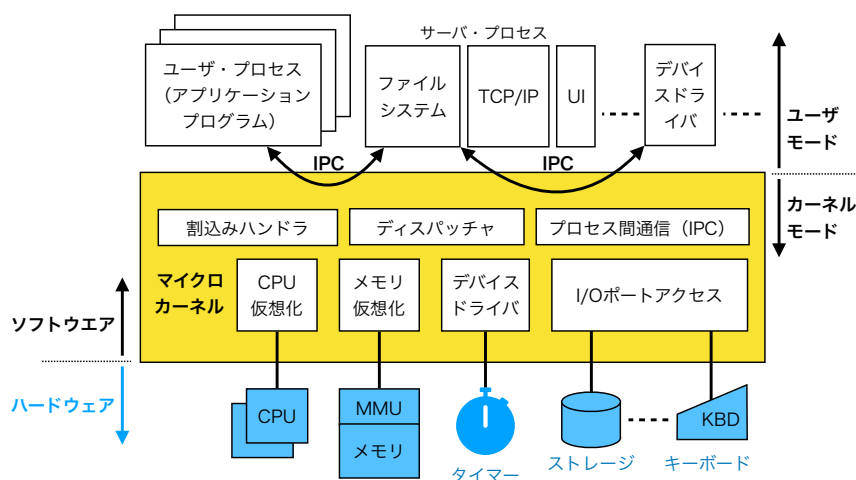


図 2.7 マイクロカーネル方式

仮想マシンについて紹介する。

2.6.1 Type 2 ハイパーバイザ

例えば、Mac を使用している人が Windows でしか動作しないアプリケーションを使用する場合を想像してしてみる^{*7}。予め Mac のハードディスクに macOS とは別に Windows もインストールしておき、電源投入時に macOS と Windows を選んでブートする方法もあるが、オペレーティングシステムを切替える度にコンピュータを再起動するのは不便である。また、macOS のアプリケーションと Windows のアプリケーションを同時に実行したい場合もある。

そこで、図 2.8 に示すような「Type 2 ハイパーバイザ (Type 2 Hypervisor)」を用いた仮想化が用いられる。ハイパーバイザはホスト・オペレーティングシステムの一つのユーザプロセスとして実行され、コンピュータの機能をエミュレーションする。ハイパーバイザがエミュレーションするコンピュータの中で、ゲスト・オペレーティングシステムが稼働する。エミュレーションはソフトウェアだけで完全に行うのではなく^{*8}、ハードウェアの支援を受けて行うので高速に行うことができる^{*9}。Type 2 ハイパーバイザとして有名な製品は、VMware Workstation, VMware Fusion, VirtualBox^{*10}等を挙げることができる。

2.6.2 Type 1 ハイパーバイザ

メインフレーム上で 1960 年代から使用されている方式である。現在では PC サーバの仮想化にも使用されている。Type 1 ハイパーバイザはホスト・オペレーティングシステム無しにハードウェア上で直接実行される。Type 1 ハイパーバイザとして有名な製品は、IBM z/VM, VMware vSphere, Xen, Hyper-V 等を挙げることができる。

サーバ向けの製品が主流であり、例えば VMware vSphere は実行中のゲストを他の物理サーバに移動する等、非常に高度な機能を持っている [36]。一台のサーバ上に効率よく多数の仮想マシンを動かすことができる。徳山高専情報電子工学科のパソコン室でも、2 台のサーバ上に 50 台の仮想デスクトップマシンを動かしていたことがある。

^{*7} 徳山高専情報電子工学科のパソコン室では、Windows や Linux でしか動作しない Xilinx ISE WebPACK を Mac で使用している。

^{*8} 完全にソフトウェアで行う場合もある。

^{*9} 詳しくは参考文献 [35]

^{*10} 徳山高専情報電子工学科のパソコン室では macOS 上の VirtualBox で Windows を動作させている。この Windows の中で Xilinx ISE WebPACK が使用できる。

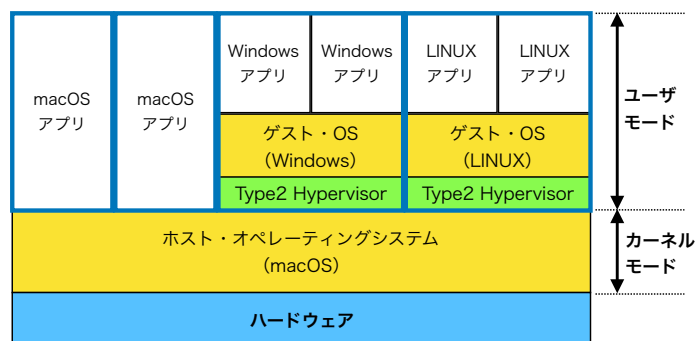


図 2.8 Type 2 ハイパーバイザ

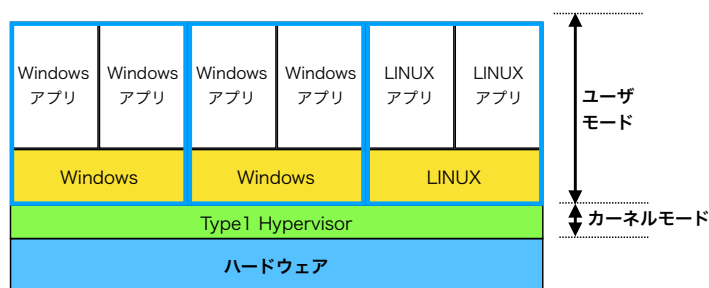


図 2.9 Type 1 ハイパーバイザ

2.6.3 仮想アプライアンス

ゲスト・オペレーティングシステムとアプリケーションまでインストールし、すぐに使用できる状態で配布される仮想マシンである。例えば、メールフィルタソフトをインストールした仮想マシンを入手しハイパーバイザで実行するだけですぐにメールフィルタリングを開始できる。

同じ手法で、すぐに使用できるパーソナルコンピュータ用のデスクトップ・オペレーティングシステムが配布されている場合もある。LINUX の一種である Ubuntu の場合、VirtualBox ですぐに実行できるディスクイメージがダウンロードできる [37]。仮想アプライアンスは、ソフトウェアの新しい流通手法である。

第 3 章

CPU の仮想化

オペレーティングシステムは、ハードウェアを抽象化した使いやすい拡張マシン（仮想マシン）を必要な数だけ提供する。数に限りがある資源が必要な数あるように見せるために仮想化が行われる。CPU 資源も仮想化し、各プロセスが自分専用の CPU を持っているように見せかける。

3.1 時分割多重

CPU を仮想化するためには時分割多重が用いられる。ハードウェアである実 CPU の数は限られているので、時間を区切って実 CPU を使用するプロセスを次々に切換えていく。図 3.1 に CPU 仮想化の原理を示す。

実 CPU は図 2.2 のような構造をもつハードウェアである。プロセスの構造は図 2.6 に示した通りであり、仮想 CPU を含んでいる。実 CPU が短時間（例えば 10ms）に次々と実行するプロセスを切換えていくことで、複数のプロセスが夫々に専用の CPU を持ち並行して実行されているように見せかける。

その際、切替える直前の CPU のコンテキストをプロセスの仮想 CPU 領域に保存する。次に、新しく実行するプロセスの仮想 CPU 領域から実 CPU にコンテキストを読み込み、新しいプロセスの実行を再開する。実 CPU にコンテキストを読み込んで実行を再開することを**ディスパッチ**と言う。ディスパッチを行うプログラムを**ディスパッチャ**と呼ぶ。図 2.5 にもディスパッチャは描かれていた。

3.2 プロセスの状態

プロセスは、キーボード等の入出力装置からの入力待つ状態になったり、時間が経過するのを待つ状態になったりする。**待ち**状態のプロセスには CPU を割当てて必要がない。このようにプロセスは幾つかの状態を持っている。プロセスの状態は UNIX では ps コマンドで確認できる。プロセスを模式的に示した図 2.6 では、「プロセス

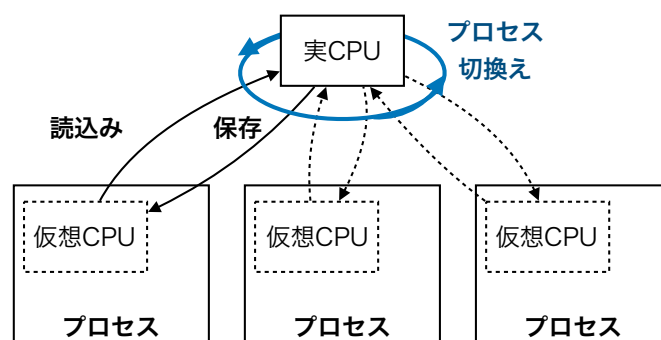


図 3.1 時分割多重による CPU の仮想化

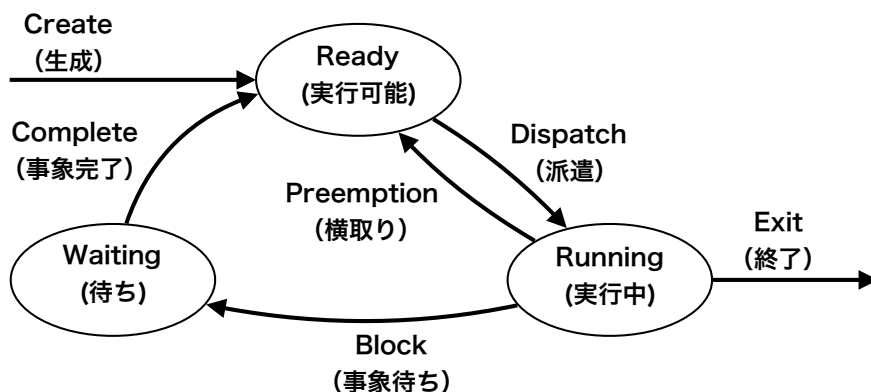


図 3.2 プロセスの状態遷移

情報」の「プロセスの状態」のことである。

3.2.1 基本的な三つの状態

図 3.2 にプロセスの状態遷移図を示す。この図は最も簡単なものであり、実際のオペレーティングシステムでは、もっと状態数が多くなる^{*1}。図に示された三つの状態を説明する。

- Ready (実行可能)
CPU を割当てれば実行を開始できる状態のことである。プロセスは CPU が割当てられるのを待っている。
- Running (実行中)
CPU が割当てられ実行している状態のことである。CPU の数より多くのプロセスが同時に Running になることはできない。
- Waiting (待ち)
シグナルの到着や入出力の完了等の事象を待っている状態である。プロセスは実行することができない。

3.2.2 状態遷移

図 3.2 に示された六つの状態遷移の意味は以下の通りである。

1. Create (生成)
新しいプロセスが生成されると Ready 状態になる。親プロセスが `fork()` システムコール (UNIX の場合) や `CreateProcess()` システムコール (Windows の場合) を実行すると、新しい子プロセスが生成される。
2. Dispatch (派遣)
Ready 状態のプロセスは、自分の順番が来たら CPU が割当てられ Running 状態に遷移し実行を開始する。
3. Preemption (横取り)
Running 状態のプロセスは、決められた時間 (クオンタムタイム) を使い切ったとき、より優先度の高いプロセスが Ready 状態になったとき等に、CPU を取り上げられて Ready 状態に遷移する。
4. Block (事象待ち)
Running 状態のプロセスが、システムコールを発行して自ら Waiting 状態に遷移することがある。例えば入出力システムコール (`open()`, `read()`, `write()`, `close()` 等) や、シグナル待ちシステムコール (`pause()`, `wait()`, `sleep()` 等) を発行した場合である。また、他のプロセスからシグナルを受信した場合も、Waiting 状態に遷移することがある。更に、仮想記憶の機能を持つオペレーティングシステムでは、プロセスが読み書きしようとした領域がメモリ上に存在しないときこの遷移が起り、メモリ領域を確保するための処理がカーネル内部で始まる。
5. Complete (事象完了)

^{*1} macOS の `ps` コマンドのオンラインマニュアルで確認すると、macOS ではプロセスの状態が、I (Idle), R (Runnable), S (Sleep), T (sTopped), U (Uninterruptible wait), Z (Zombi) の六つであることが分かる。

Waiting 状態のプロセスは、入出力の完了やシグナルの発生等の事象（イベント）が発生すると Ready 状態に遷移する。Waiting 状態のプロセスは停止しているのでプロセスが事象を発生することはない。事象はプロセスの外部からもたらされる。

6. Exit（終了）

プロセスが自ら `exit()` システムコール（UNIX の場合）や `ExitProcess()` システムコール（Windows の場合）を用いて終了する場合、プロセスがシグナルを受ける等して終了させられる場合に、この遷移が起こる。シグナルはプロセス（他プロセス、自プロセス）から明示的に送信される場合と、自プロセスが保護違反などのエラーを起こして発信される場合がある。

3.3 プロセスの切換え

Running 状態のプロセスが Block 遷移または Preemption 遷移し CPU を取り上げられると、他のプロセスが CPU を割付けられ Dispatch 遷移し実行される。

3.3.1 切換えの原因

Running 状態のプロセスが状態遷移を起こす原因を以下にまとめ直す。

1. イベント

Running 状態のプロセスは、自ら「システムコールを発行」することで Block 遷移をすることがある。また、他のプロセスからの「干渉^{*2}を受け」Block 遷移することがある。

2. タイムスライシング

Running 状態のプロセスが長時間の実行を続けると Preemption 遷移をする。一度に実行しても良い時間（クオンタムタイム）を使い切ったためである。Ready 状態のプロセスが他にあれば、そのプロセスに実行が切換わる。他に実行すべきプロセスが無い場合は、再度、同じプロセスが実行される。

3.3.2 切換え手順

図 3.3 に二つのプロセス間で実行が切り換わる様子を示す。図では時間に従って上から下へ処理が進んでいく。左側はプロセス A の実行を、右側はプロセス B に実行を、図の中央はカーネルの実行を表している。プロセスの実行が切り替わっていく手順を以下で説明する。

1. 実行

日頃は CPU がユーザ・プロセスを実行している。

2. 割込み

割込みが発生し処理がプロセス A からカーネル内の割込みハンドラに移る。割込みの原因は 2.4.2 で述べた様々な原因が考えられる。割込みが発生すると以下の処理が CPU のハードウェアにより自動的にされる。

- (a) CPU の（PC を含む）PSW がスタックに保存される。
- (b) CPU の実行モードがカーネルモードに切り換わる。
- (c) 割込みハンドラにジャンプする。

3. 割込みハンドラ

PSW（スタック上にある）と CPU レジスタ（図 2.2 参照）からなるプロセスのコンテキストをプロセスの仮想 CPU 領域（図 2.6 参照）に保存する。次に割込み原因を調べ、割込み原因に応じた処理（サービスモジュール等）にジャンプする。例えば、割込み原因が `open()` システムコールなら、`open` システムコールの処理を行うファイルシステムのサービスモジュールにジャンプする。割込み原因が I/O 完了なら、完了した I/O に対応するデバイスドライバにジャンプする。

4. サービスモジュール等

割込み原因に応じた処理を行う。この過程でプロセスの状態が変化させることがある。例えば、プロセスが発行したシステムコールが原因で Block 遷移する場合や、タイマーや I/O の完了割込により Waiting 状態だった別のプロセスが Complete 遷移する場合、タイマーの完了割込により現在のプロセスが Preemption 遷移

^{*2} 干渉には、より優先順位の高いプロセスが実行可能になった、別のプロセスからシグナル等を受取った等がある。

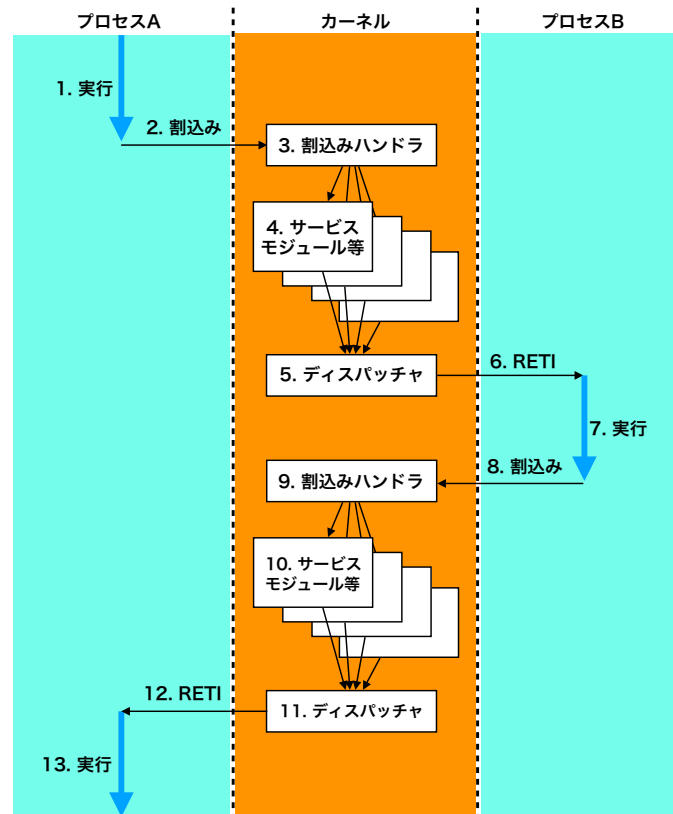


図 3.3 プロセスの切換え

する場合等が考えられる。サービスモジュールの処理が完了するとディスパッチャにジャンプする。

5. ディスパッチャ

実行可能なプロセスの中から適切な一つを選び、選んだプロセスの仮想 CPU 領域の内容を CPU レジスタにロードする。最後に PSW を復旧する機械語命令を実行しコンテキストを完全に CPU にロードし、プロセスの実行に戻る。CPU の実行モードを表すフラグは PSW に含まれているので、PSW が復旧されることで実行モードがカーネルモードからユーザモードに切り換わる。PSW を復旧する機械語命令として割り込復帰用の **RETI (RETurn from Interrupt) 命令**を用いる。RETI 命令は単一の命令で PSW (PC とフラグ) を一度にスタックから復旧する。

6. 実行

新しく選択されたユーザ・プロセスが実行される。

図 3.3 の下半分、プロセス B からプロセス A へ実行が移る手順も上と同様である。

3.3.3 切換えの例

計算に長い時間を要する二つのプロセスだけがある時、クオンタムタイムを使い切ってもう一方のプロセスに切り換わり、交互に実行される様子を図 3.4 に示す。以下に手順を説明する。

1. 実行

プロセス A は計算処理を続けている。長い時間に渡ってシステムコールを発行することは無い。

2. タイマー割り込み

タイマーは一定間隔で割り込みを発生する。割り込みが発生すると CPU のハードウェアが自動的に PSW を保存し、割り込みハンドラにジャンプする。オペレーティングシステムは、主に、この割り込みを基準に時間の経過を認識する。

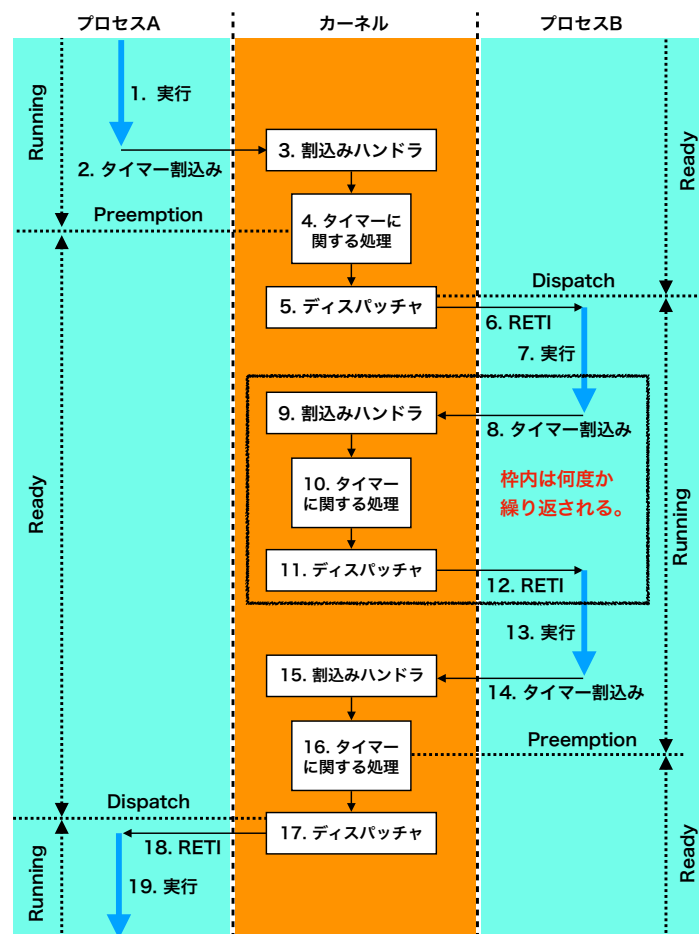


図 3.4 プロセスの切換えの例

3. 割り込みハンドラ

プロセスのコンテキストをプロセスの仮想 CPU に保存する。その後、割込原因を調べタイマーからの割込みなので、「タイマーに関する処理」を行うカーネル内のモジュールへジャンプする。

4. タイマーに関する処理

一定間隔で発生するタイマーからの割込みを利用して、システムの時計を進めたり、リソース（CPU やメモリ等）の利用統計データを更新したりする。その間にプロセス A がクオンタムタイムを使い切ったことが判明すると、プロセス A を Preemption 遷移させる。この時点でプロセス A の状態が Ready に変化する。

5. ディスパッチャ

Ready 状態のプロセスの中から適切な一つを選び Dispatch 遷移させる。図 3.4 はプロセス B が選択された場合である。ディスパッチャはプロセス B の CPU レジスタを復旧する。

6. RETI

プロセス B の PSW を復旧し、プロセス B の実行を再開する。

7. 実行

プロセス B は計算処理を再開する。プロセス B も長い時間計算を続けるプロセスとする。

8. タイマー割り込み

計算を続けるうちにタイマーからの割込みが発生する。

9. 割り込みハンドラ

プロセス B のコンテキストを保存する。

10. タイマーに関する処理
プロセス B は、まだ、クオンタムタイムを使い切っていないので、Preemption は発生しない。
11. ディスパッチャ
Preemption は発生しないので、プロセス B のコンテキストを復旧する。
12. RETI
プロセス B に戻る。
13. 実行
プロセス B は計算処理を再開する。
14. タイマー割込み
8.~13. を何度か繰り返し、クオンタムタイムを使い切った時のタイマー割込みである。
15. 割込みハンドラ
プロセス B のコンテキストを保存する。
16. タイマーに関する処理
クオンタムタイムを使い切ったので Preemption が発生する。
17. ディスパッチャ
Ready 状態のプロセス A を選択し Dispatch 遷移させる。プロセス A のコンテキストを復旧する。
18. RETI
プロセス A に戻る。
19. 実行
プロセス A は計算処理を再開する。

3.4 PCB (Process Control Block)

PCB はプロセス毎に用意される最も重要なカーネルのデータ構造である。PCB はカーネル内のプロセステーブルに格納される。

3.4.1 PCB の内容

図 2.6 に示した模式的なプロセスの構造図の「仮想 CPU」と「プロセス情報」を合わせたものが PCB に相当する。PCB には以下のような情報が格納される。

- 仮想 CPU
- プロセス番号
- 状態 (Running, Waiting, Ready 等)
- 優先度
- 統計情報 (CPU 利用時間等)
- 次回のアラーム時刻
- 親プロセス
- 子プロセス一覧
- シグナルハンドリング
- 使用中のメモリ
- オープン中のファイル
- カレントディレクトリ
- プロセス所有者のユーザ番号
- PCB のリストを作るためのポインタ

3.4.2 PCB リスト

PCB はプロセスを表現するデータ構造である。例えば、Ready 状態のプロセスは優先度順にソートされ、優先順位が最も高いものから順に CPU が割当てられる。ソートされた Ready 状態のプロセスのリストは、優先度をキーにソートされた PCB の線形リスト (待ち行列) として表現される。その様子を図 3.5 に示す。図は、数値が

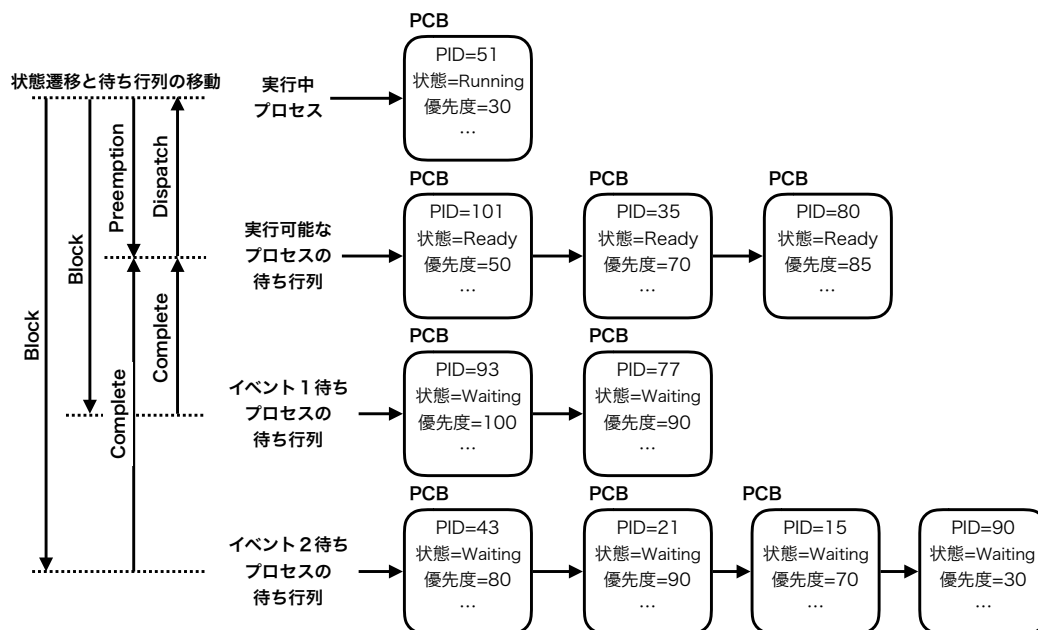


図 3.5 PCB のリスト

小さいほど優先度が高い意味になっている。

Ready 状態のプロセスだけでなく、Running 状態のプロセスや、Waiting 状態のプロセスも待ち行列として表現される。Waiting 状態のプロセスは、待ち合わせているイベント毎に待ち行列を作っている。イベント待ちの待ち行列のソート順はイベント毎にルールが決められる。

プロセスの状態遷移に合わせて PCB が待ち行列の間を移動する。図 3.5 の左側の「状態遷移と待ち行列の移動」が「どの待ち行列から、どの待ち行列に移動可能か」を表している。例えば、Running 状態（実行中）のプロセスが Preemption 遷移をすると、状態が Ready に変わるだけでなく、PCB が「実行可能なプロセスの待ち行列」に移動する。この移動ルールは図 3.2 の状態遷移と一致している。

3.5 CPU 仮想化の実例

実例として TacOS^{*3}の例を紹介する。TacOS はマルチプロセスのオペレーティングシステムである。以下では CPU の時分割多重に必要なプロセス切換え機構を紹介する。

3.5.1 TacOS の PCB

PCB はプロセス切換え機構にとっても最も重要なデータ構造である。TacOS の PCB は図 3.6 に示す PCB 構造体として定義されている^{*4}。PCB 構造体の内容を順に説明する。

- 仮想 CPU(sp)

TacOS はプロセスのコンテキストのほとんどをカーネルスタック上に保存する。そして、保存位置を表すスタックポインタ (SP) だけを PCB に保存する。PCB に保存されるのは仮想 CPU の一部だけである。

- プロセス番号 (pid)

- 状態 (stat)

TacOS のプロセスの状態は以下の三つである。

^{*3} TacOS の詳細は <https://github.com/tctsigemura/TacOS> を参照のこと。

^{*4} 図 3.6 は TacOS のソースコード <https://github.com/tctsigemura/TacOS/blob/master/os/kernel/process.h> の一部である。

```

1  #define P_RUN    1          // プロセスは実行可能または実行中
2  #define P_SLEEP  2          // プロセスは実行不可能
3  #define P_ZOMBIE 3          // プロセスは実行終了
4
5  // プロセスコントロールブロック (PCB)
6  //   優先度は値が小さいほど優先度が高い
7  struct PCB {               // PCB を表す構造体
8      int sp;                 // コンテキスト (他の CPU レジスタと PSW は
9                              //   プロセスのカーネルスタックに置く)
10     int pid;                 // プロセス番号
11     int stat;                // プロセスの状態
12     int nice;                // プロセスの本来優先度
13     int enice;               // プロセスの実質優先度 (将来用)
14     int idx;                 // この PCB のプロセステーブル上のインデクス
15
16     // プロセスのイベント用セマフォ
17     int evtCnt;              // カウンタ (>0:sleep 中, ==-1:wait 中, ==0:未使用)
18     int evtSem;              // イベント用セマフォの番号
19
20     // プロセスのアドレス空間 (text, data, bss, ...)
21     char[] memBase;          // プロセスのメモリ領域のアドレス
22     int memLen;              // プロセスのメモリ領域の長さ
23
24     // プロセスの親子関係の情報
25     PCB parent;              // 親プロセスへのポインタ
26     int exitStat;            // プロセスの終了ステータス
27
28     // オープン中のファイル一覧
29     int[] fds;               // オープン中のファイル一覧
30
31     // プロセスは重連結環状リストで管理
32     PCB prev;                // PCB リスト (前へのポインタ)
33     PCB next;                // PCB リスト (次へのポインタ)
34     int magic;               // スタックオーバーフローを検知
35 };

```

図 3.6 TacOS の PCB 宣言ソースプログラム

1. P_RUN

Running と Ready の二つを兼用している。プロセスは実行可能プロセスの待ち行列（実行可能列）に挿入される際に P_RUN 状態になる。実行中も P_RUN 状態のまま変更しない。

2. P_SLEEP

Waiting 状態のことである。

3. P_ZOMBIE

プロセスが終了したが、終了ステータスを親プロセスに渡していない状態である。終了処理の途中状態と考えるとよい。

● 優先度 (nice, enice)

ゼロが最も高い優先度を表す。優先度には、本来の優先度 (nice) と、実質の優先度 (enice) の二つがある。現在の実装ではこの二つは同じ値を持つ。将来、動的に変化する優先度を採用する場合に、enice の値が変化するようにする。

● プロセステーブルのインデクス (idx)

この PCB が登録されているプロセステーブル内の位置である。プロセスが消滅する際にプロセステーブルから PCB を削除するために使用する。

● イベント用カウンタとセマフォ (evtCnt, evtSem)

セマフォはプロセス間の同期に使用する基本的な機構である^{*5}。タイマー待ち、子プロセスの終了待ち等で、このセマフォを使用してプロセスを待ち状態にする。カウンタはタイマーの待ち時間を計るため等に使われる。

● プロセスのアドレス空間 (memBase, memLen)

TacOS には仮想記憶のような高度な機構は無い。各プロセスは、物理メモリの領域をオペレーティングシステムによって割付けられる。memBase はオペレーティングシステムがプロセスに割当てたメモリ領域の開始アドレス、memLen はメモリ領域のバイト数である。

● プロセスの親子関係の情報 (parent, exitStat)

TacOS のプロセスは親プロセスだけ記憶している。parent は親プロセスの PCB を指すポインタである。exitStat は P_ZOMBIE 状態になった時、親に渡すべき終了ステータスを保存する領域である。

● オープン中のファイル一覧 (fds)

プロセスがオープンしたファイルのファイルディスクリプタ (番号) の一覧を記憶する配列である。TacOS ではシステム全体で一意的なファイルディスクリプタ (番号) が用いられる^{*6}。close() システムコールは、クローズするファイルディスクリプタが正当なものか調べるために、この配列を使用する。exit() システムコールは、プロセスを終了する前にプロセスの全オープンファイルをクローズするために、この配列を使用する。

● PCB リストの管理 (prev, next)

TacOS はプロセスのリストを PCB のリストとして表現する。TacOS の PCB リストは番付きの重連結環状リストである (図 3.8 参照)。prev, next はリスト上で前後のプロセスの PCB を指すポインタである。

● スタックオーバーフローの検知 (magic)

TacOS は PCB の直後にプロセスのカーネルスタックを配置する。万一、カーネルスタックがオーバーフローすると PCB が後ろから破壊される。magic はそれを検知するために使用される。TacOS は PCB を初期化する際に magic に 0xabcd を格納する。カーネルスタックがオーバーフローすると、まず、magic 領域が破壊される。magic の値が変化していないかチェックすることで、カーネルスタックのオーバーフローを検知することができる。

^{*5} 詳しくは後の章で解説する。

^{*6} UNIX のファイルディスクリプタ (番号) はプロセス毎に 0 番から割振られる。

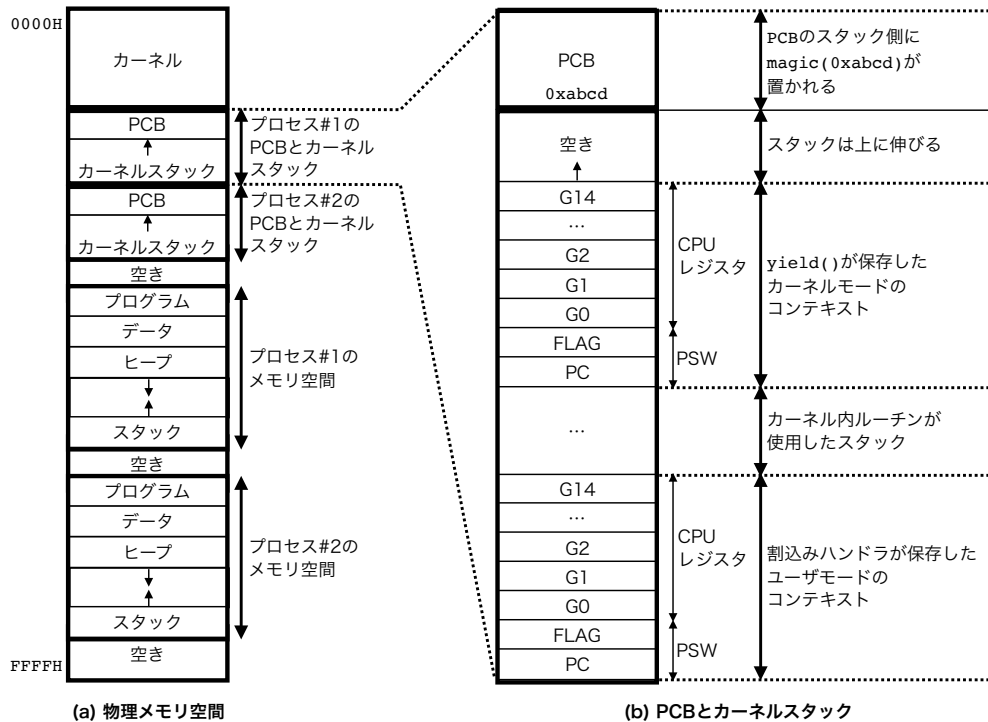


図 3.7 TacOS のメモリ配置

3.5.2 TacOS のメモリ配置

図 3.7 に TacOS 実行時のメモリマップを示す。図は二つのプロセスが実行中の例である。まず「物理メモリ空間」の配置について、次に「PCB とカーネルスタック」について説明する。

(a) 物理メモリ空間

- カーネル
カーネルのプログラムとデータ（変数）がこの領域に配置される。
- プロセス # 1 の PCB とカーネルスタック
プロセス 1 の PCB とカーネルスタックが隣接して配置される。詳細は図 3.7(b) に示してある。
- プロセス # 2 の PCB とカーネルスタック
プロセス毎に PCB とカーネルスタックが準備される。
- プロセス # 1 のメモリ空間
プロセス 1 のプログラム、データ、ヒープ、スタック領域が配置される。ユーザモードのプロセスは、この範囲以外のメモリをアクセスできないように保護すべきである。しかし、TaC はメモリ保護機構を持っていない。
- プロセス # 2 のメモリ空間
プロセス毎にメモリ空間が準備される。

(b) PCB とカーネルスタック

PCB とカーネルスタックはプロセスの生成時に隣接して領域が確保される。ユーザプログラム実行中はスタックの内容が空になる（スタックポインタがスタック領域の最大アドレスを指す。）。割り込みが発生すると自動的に PSW がカーネルスタックに保存され、実行モードがカーネルモードに切替わる。次に割り込みハンドラに制御が移り CPU レジスタをスタックに保存した後、カーネル内ルーチンの実行が始まる。カーネル内ルーチンは、PCB に向かって伸びるカーネルスタックを使用する。そこで、PCB の最もスタック寄りにマジックナンバー (0xabcd) を配置し、スタックが伸びすぎ PCB を破壊したことを検知するために使用する。

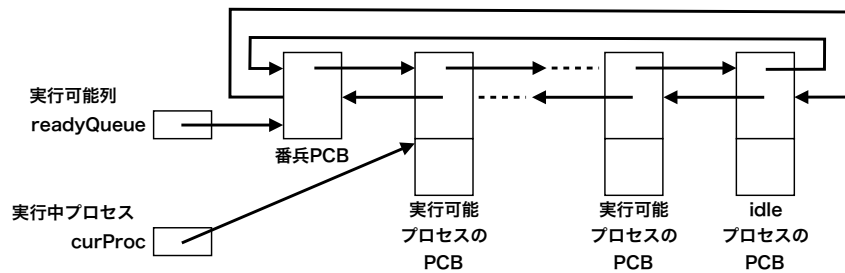


図 3.8 TacOS の実行可能列

3.5.3 TacOS のプロセス切換えプログラム

図 3.9 に TacOS のプロセス切換えプログラムを示す^{*7}。切換えプログラムは、コンテキストを保存する `yield()`^{*8} と復旧する `dispatch()`^{*9} からなる。`dispatch()` は図 3.8 に示す実行可能列の先頭プロセスを実行する。TacOS は、PCB を実行可能列に置いたままプロセスを実行する。TacOS は、図 3.7(b) に示すように、プロセス毎にユーザモードとカーネルモードの二つのコンテキストを保存する。

割込が発生しカーネル内に実行が移ると、まず、割込みハンドラがユーザモードのコンテキストをカーネルスタックに保存する。次に、カーネルモードでカーネル内のプログラムが実行される。この時点では、割込み前のプロセスの一部として実行されている。プロセスを切換えるためには `yield()` を呼出す。`yield()` はカーネルモードのコンテキストをカーネルスタックに追加保存し、新しいプロセスの実行に切換える。次回、プロセスの実行が再開されるのは、カーネル内の `yield()` を呼出した位置になる。次に図 3.9 の内容を解説する。

2 行 プロセスを切換える時にカーネル内で呼出される `yield()` 関数の入口である。このルーチンは現在のプロセスのコンテキストを保存し CPU を解放する。

3~16 行 プロセスのカーネルモードのコンテキストをスタックに保存する処理である。`yield()` が (CALL 命令で) 呼出された時点で PC はスタックに格納されている。後で RETI 命令で PC と FLAG を同時に復旧するので PC の次に FLAG を格納している (7 行、図 3.7(b) 参照)。

17~19 行 プロセスのカーネルモードのコンテキストを保存したスタックの位置を PCB に保存する。`_curProc` 変数には現在のプロセスの PCB を指すポインタが保存されている (図 3.8 参照)。PCB 先頭の `sp` 領域 (図 3.6 参照) にスタックポインタを保存する。ここまでの処理でコンテキストの保存が完了した。

20~23 行 カーネルスタックがオーバーフローしていないか調べる。PCB の `magic` フィールドの値をチェックし `0xabcd` 以外の値になっていたら、カーネルスタックが隣接する PCB まで伸びた (オーバーフローした) と判断する。この場合、`.stkOverflow` ルーチンにジャンプしシステムを停止する。カーネルのエラーなので復旧は諦める。オーバーフローが検知されない場合は 26 行に進み、新しいプロセスにディスパッチする。

26 行 プロセスに CPU を割り付けるディスパッチャ (`dispatch()` 関数) の入口である。

27~31 行 まず、実行可能列 (`_readyQueue`) の先頭プロセスの PCB アドレスを `_curProc` 変数にセットする。実行可能列は番兵付きの重連結環状リストなので番兵の次が先頭の PCB である (図 3.8 参照)。実行可能なプロセスが無い場合は `idle` プロセスが選択される。`_curProc` が更新されたので、新しいプロセスが現在のプロセスになった。次に、現在のプロセスの保存してあったスタックポインタ (`sp`) を復旧する。

31~42 行 スタックポインタが復旧されたので、スタックから CPU レジスタを復旧する。

43~44 行 RETI 命令を用いて PSW (FLAG と PC) を復旧し、前回プロセスが `yield()` を呼出した位置に戻る。`yield()` を呼出した位置に戻るために RET 命令ではなく RETI 命令を使用するのは、プロセス生成時は例外的に、この RETI で実行モードを切換えてユーザプログラムの実行を開始するからである。

^{*7} 図 3.9 は TacOS のソースコード <https://github.com/tctsigemura/TacOS/blob/master/os/kernel/dispatcher.s> の一部である。プログラムは TaC のアセンブリ言語で記述してある。

^{*8} 高級言語から `yield()` 関数を呼出すと、アセンブリ言語の `_yield` ルーチンが実行される。

^{*9} 高級言語から `dispatch()` 関数を呼出すと、アセンブリ言語の `_dispatch` ルーチンが実行される。

```

1 ; 現在のプロセス (curProc) が CPU を解放する。その後、新プロセスヘディスパッチする。
2 _yield                                ; 高級言語からは yield() 関数として呼出す。
3     ;--- G13(SP) 以外の CPU レジスタと FLAG をカーネルスタックに退避 ---
4     push    g0                        ; FLAG の保存場所を準備する
5     push    g0                        ; G0 を保存
6     ld      g0,flag                   ; FLAG を上で準備した位置に保存
7     st      g0,2,sp                   ;
8     push    g1                        ; G1 を保存
9     push    g2                        ; G2 を保存
10    push    g3                        ; G3 を保存
11    ...
12    ...                                ; G4 から G10 も同様に保存する
13    ...
14    push    g11                       ; G11 を保存
15    push    fp                        ; フレームポインタ (G12) を保存
16    push    usp                       ; ユーザモードスタックポインタ (G14) を保存
17    ;----- G13(SP) を PCB に保存 -----
18    ld      g1,_curProc               ; G1 <- curProc
19    st      sp,0,g1                   ; [G1+0] は PCB の sp フィールド
20    ;----- [curProc の magic フィールド] をチェック -----
21    ld      g0,30,g1                  ; [G1+30] は PCB の magic フィールド
22    cmp     g0,#0xabcd                ; P_MAGIC と比較、一致しなければ
23    jnz     .stkOverflow               ; カーネルスタックがオーバーフローしている
24 ;
25 ; 最優先のプロセス (readyQueue の先頭プロセス) ヘディスパッチする。
26 _dispatch                            ; 高級言語からは dispatch() 関数として呼出す。
27     ;----- 次に実行するプロセスの G13(SP) を復元 -----
28     ld      g0,_readyQueue           ; 実行可能列の番兵のアドレス
29     ld      g0,28,g0                 ; [G0+28] は PCB の next フィールド (先頭の PCB)
30     st      g0,_curProc              ; 現在のプロセス (curProc) に設定する
31     ld      sp,0,g0                 ; PCB から SP を取り出す
32     ;----- G13(SP) 以外の CPU レジスタを復元 -----
33     pop     usp                      ; ユーザモードスタックポインタ (G14) を復元
34     pop     fp                      ; フレームポインタ (G12) を復元
35     pop     g11                     ; G11 を復元
36     ...
37     ...                                ; G10 から G4 も同様に復元する
38     ...
39     pop     g3                      ; G3 を復元
40     pop     g2                      ; G2 を復元
41     pop     g1                      ; G1 を復元
42     pop     g0                      ; G0 を復元
43     ;----- PSW(FLAG と PC) を復元 -----
44     reti                             ; RETI 命令で一度に POP して復元する

```

図 3.9 TacOS のプロセス切換えプログラム

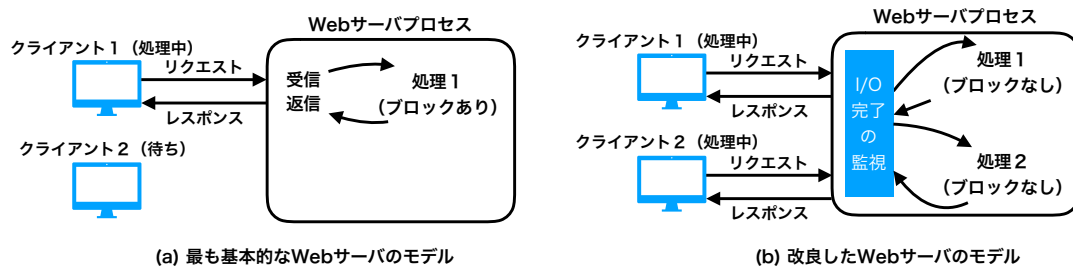


図 3.10 マルチプログラミングを用いない Web サーバ

3.6 スレッド (Thread)

ここまで、一つのプロセスが一つの仮想 CPU を持つモデルを考えてきた。しかし、実際のコンピュータのハードウェアは CPU を複数持つ場合がある。これでは「ハードウェアの機能を抽象化した便利な**拡張マシン**」(1.1.1 参照)であるはずのプロセスが、「CPU が一つしかない**縮小マシン**」になっている。そこで、プロセスが複数の仮想 CPU を持つモデルを導入する。これにより、一つのプロセスに並列実行する複数の処理の流れ（スレッド）を持つことが可能になる。

3.6.1 スレッドの役割

複数のプロセス（ジョブ）を主記憶にロードしておくことで CPU の利用効率を高くできることは既に説明した（4 ページ、マルチプログラミング参照）。マルチプログラミングの、もう一つのメリットは、プログラミングが簡単になる場合があることである。以下では Web サーバを例に、マルチプログラミングによる改善を紹介する。

- マルチプログラミングなし

図 3.10(a) に最も簡単なモデルを示す。Web サーバはリクエストを受信すると、それに対するレスポンスを返す。処理は 1 番目のクライアントから順に行われ、2 番目のクライアントは 1 番目の処理が終了するまで待たされる。このモデルの問題点は、処理中に Web サーバプロセスが I/O 待ち等でブロック（Block）する可能性があり、その間、他のクライアントへのサービスがされないことである。

2 番目以降のクライアントが長時間待たされないように、複数のクライアントの処理を並行してできるように改良したモデルが図 3.10(b) である。「I/O 完了の監視」は通信を含む複数の入出力を同時に監視し、どれかが読み書き可能になるのを待つ機能である。UNIX では `select()` システムコールがこの機能を持つ。読み書き可能になったことを確認後に読み書きを行うのでプロセスがブロックすることが無くなり、複数のクライアントに対して同時にサービスを行うことができる。

しかし、Web サーバのプログラミングは難しくなる。一方のクライアントの処理が終わらないうちに、別のクライアントの処理を開始する必要があるからである。クライアント毎に処理がどこまで進んでいるのかを表す**状態**を持つ必要がある。また、CPU が複数存在する場合でも、同時には一つの CPU しか働かないことも問題である。

- マルチプロセス

マルチプログラミングを用いることで前記の問題を解決したモデルを図 3.11(a) に示す。Web サーバプロセスは、まず、接続要求を待ちクライアント 1 からの接続を受け入れる。次に、クライアント 1 専用のサーバプロセスを生成し処理を任せる。Web サーバプロセスは、生成したプロセスの終了を待たずに、次の接続要求待ちになる。クライアント 2 からの接続要求があったらクライアント 2 専用のサーバプロセスを生成し、接続要求待ちに戻る。

このモデルなら、各クライアントの処理を別々のプロセスが行っているのだから、プロセスがブロックしても構わない。そのため、プログラミングは簡単になる。また、CPU が複数あればプロセスが真に並列に実行される。しかし、プロセスの生成はメモリ空間の確保や初期化を含み**重い処理**である。また、プロセスはメモリを共有していないのでプロセス間の情報共有には効率が悪い。

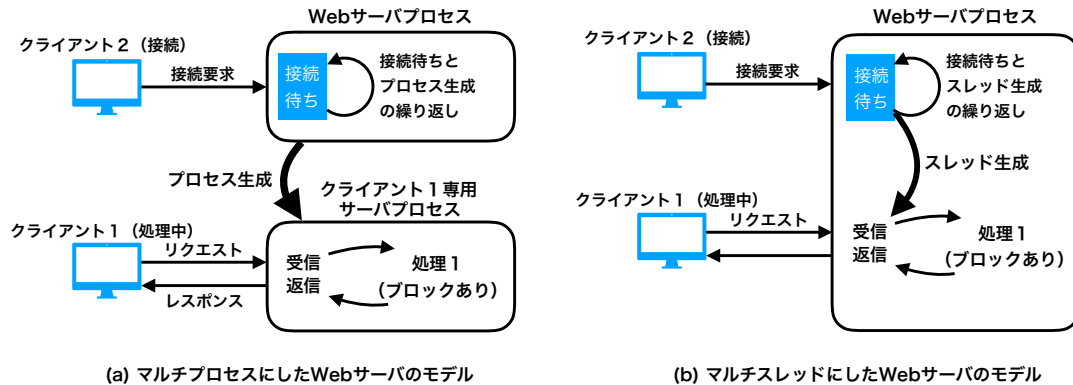


図 3.11 マルチプログラミングを用いる Web サーバ

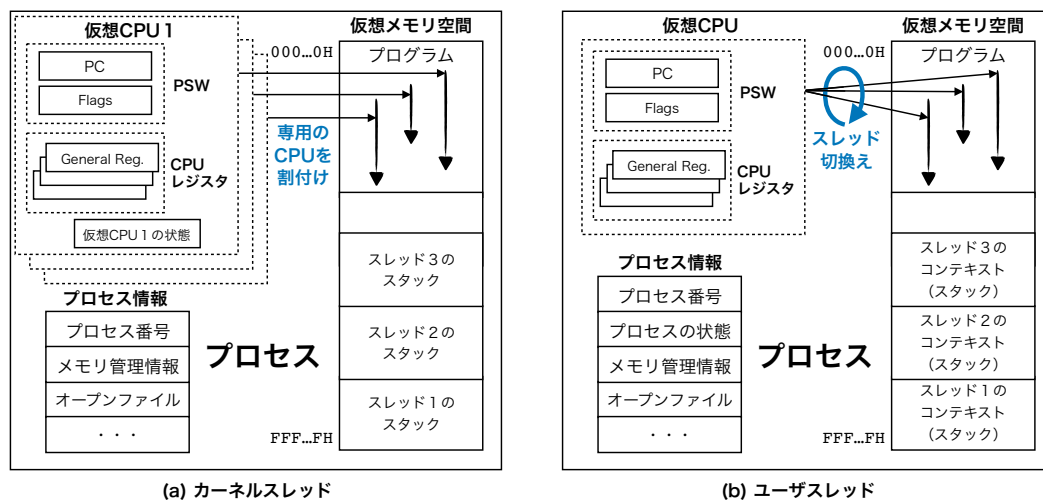


図 3.12 ユーザスレッドとカーネルスレッド

● マルチスレッド

複数のスレッドを使用したモデルを図 3.11(b) に示す。マルチプロセスの場合と良く似たプログラムであるが、クライアント毎に専用のプロセスを作る代わりに、クライアント毎に専用のスレッドを作る。スレッドの生成はプロセス生成より 10～100 倍速いと言われている [38]。また、スレッドはメモリを共有しているので情報共有には都合が良い。例えば、Web サーバが頻繁に参照されるページをメモリ上にキャッシュする場合、キャッシュをスレッドで共有できる。

3.6.2 スレッドの形式

読者は、スレッドをカーネルが実現すると暗黙のうちに考えていたかも知れない。しかし、ユーザプログラム（ライブラリ）内でスレッドを実現することもある。カーネルが実現するスレッドを**カーネルスレッド**、ユーザプログラム内で実現するスレッドを**ユーザスレッド**と呼ぶ。

● カーネルスレッド

カーネルスレッドの模式図を図 3.12(a) に示す。カーネルスレッドはプロセスの仮想 CPU を複数にし、仮想 CPU がプログラムを並行して実行する。「プロセス情報」から「プロセスの状態」は無くなり、代わりに仮想 CPU 毎に「仮想 CPU の状態」を管理するようになる。CPU が複数ある時、カーネルスレッドであれば、プロセス内を真に並列実行することが可能である。

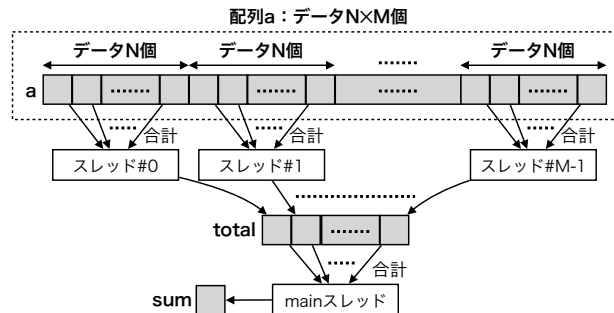


図 3.13 M 個のスレッドで手分けして合計を計算する様子

- ユーザスレッド

ユーザスレッドの模式図を図 3.12(b) に示す。プロセスには単一の仮想 CPU しかない。ユーザスレッドは仮想 CPU を時分割多重して実現される。カーネルを経由しないでスレッドの生成や切換えをすることができるので、オーバーヘッドが非常に小さい。

以下に述べるように、両者を組合せた三つのスレッドモデルが使用される。

1. Many-to-One Model

複数 (Many) のユーザスレッドを一つ (One) のカーネルスレッドで実行するモデルである。図 3.12(b) に相当する。プロセス内にカーネルスレッドは一つしか存在しない。ユーザスレッドはユーザプログラム (ライブラリ) の工夫で単一のカーネルスレッドを複数に見せかけているだけなので、真の並列実行にはならない。また、何れかのスレッドがシステムコールでブロックすると、全てのスレッドが停止してしまう問題がある。

2. One-to-One Model

全てのスレッドがカーネルスレッドのモデルである。図 3.12(a) に相当する。プロセス内にカーネルが管理する仮想 CPU が複数あるので、複数プロセスと同等な並列実行が可能である。しかし、スレッドの生成や切換えにカーネルが介入するので、処理は重くなる。また、システムによっては生成できるスレッド数に制限がある。

3. Many-to-Many Model

複数の (Many) のユーザスレッドを複数の (Many) のカーネルスレッドで実行するモデルである。カーネルスレッドの数をユーザスレッドの数より多くすることはない。前記二つのモデルの折衷案である。

3.6.3 スレッドプログラミング

配列データの合計を求める処理をスレッドを用いて高速化する例を考えよう。図 3.13 に原理を示す。配列 a を M 分割し個別スレッドで (CPU が複数あれば) 同時に小計を計算する。小計は配列 total に格納する。最後に main スレッドが total の合計を求めると全体の合計 sum が計算できる。

POSIX スレッドによる実装

このアイデアを POSIX スレッド^{*10}を用いた C 言語プログラムにしたものを図 3.14^{*11}に示す。

12 行の `thread()` 関数は M 個のスレッドで同時に並列実行される。配列 a の担当範囲等は引数 `arg` により指示される。関数の引数 (`arg`) やローカル変数 (`args`, `sum`, `i`) は、スレッドのスタック (図 3.12 参照) に割り付けられるので、スレッド毎に別の実体を持つ。グローバル変数 `a` や `total` 等は全てのスレッドで共有される。

33 行の `pthread_attr_init()` は引数の `pthread_attr_t` 型変数をデフォルトのアトリビュート値で初期化する。34 行の `pthread_create()` がスレッドを生成する関数である。新しいスレッドの実行は引数で指定された関数 `thread()` から始まる。`pthread_create()` の引数 `p` は `thread()` 関数の `arg` に実行開始時に渡される。

39 行の `pthread_join()` はスレッドの終了を待つ関数である。スレッドの終了が確認できたら、40 行で小計を

^{*10} POSIX スレッドは UNIX 系のオペレーティングシステムで利用できる。

^{*11} このプログラムは macOS High Sierra で動作確認をした。

```

1  #include <stdio.h>
2  #include <stdlib.h>
3  #include <pthread.h>
4  #define N 1000                                // 1スレッドの担当データ数
5  #define M 10                                  // スレッド数
6  pthread_t tid[M];                             // M個のスレッドのスレッド ID
7  pthread_attr_t attr[M];                       // M個のスレッドの属性
8  int a[M*N];                                   // このデータの合計を求める
9  int total[M];                                  // 各スレッドの求めた部分合
10 typedef struct { int no, min, max; } Args;      // スレッドに渡す引数の型定義
11
12 void *thread(void *arg) {                      // 自スレッドの担当部分のデータの合計を求める
13     Args *args = arg;                          // m 番目のスレッド
14     int sum = 0;                                // 合計を求める変数
15     for (int i=args->min; i<args->max; i++) {    // a[N*m ... (N+1)*m] の
16         sum += a[i];                            // 合計を sum に求める.
17     }
18     total[args->no]=sum;                         // 担当部分の合計を記録
19     return NULL;                                // スレッドを正常終了する
20 }
21
22 int main() {                                    // main スレッドの実行はここから始まる
23     // 擬似的なデータを生成する
24     for (int i=0; i<M*N; i++) {                 // 配列 a を初期化
25         a[i] = i+1;
26     }
27     // M 個のスレッドを起動する
28     for (int m=0; m<M; m++) {                   // 各スレッドについて
29         Args *p = malloc(sizeof(Args));          // 引数領域を確保
30         p->no = m;                               // m 番目のスレッド
31         p->min = N*m;                             // 担当範囲下限
32         p->max = N*(m+1);                         // 担当範囲上限
33         pthread_attr_init(&attr[m]);             // アトリビュート初期化
34         pthread_create(&tid[m], &attr[m], thread, p); // スレッドを生成しスタート
35     }
36     // 各スレッド終了を待ち, 求めた小計を合算する
37     int sum = 0;
38     for (int m=0; m<M; m++) {                   // 各スレッドについて
39         pthread_join(tid[m], NULL);              // 終了を待ち
40         sum += total[m];                         // 小計を合算する
41     }
42     printf("1+2+ ... +%d=%d\n", N*M, sum);
43     return 0;
44 }

```

図 3.14 M 個のスレッドで分担して配列データの合計を求めるプログラム

表 3.1 スレッド数による実行時間比較

M N M*N	スレッド数 (M) ・ データ件数 (M*N)					
	1	2	3	4	5	10
	10,000 10,000	5,000 10,000	3,333 9,999	2,500 10,000	2,000 10,000	1,000 10,000
経過時間 (s)	2.338	1.133	1.034	0.964	0.960	0.961
ユーザ CPU 時間 (s)	2.323	2.239	3.015	3.683	3.710	3.722
システム CPU 時間 (s)	0.007	0.005	0.006	0.007	0.006	0.007




図 3.15 スレッド数による実行時間の変化

sum に足し込んでいる。

実行時間の測定結果

図 3.14 のプログラムの実行時間の測定結果を表 3.1 に示す^{*12*13}。また、グラフにしたものを図 3.15 に示す。

スレッド数が 1 の時は、経過時間 (Real) とユーザ CPU 時間 (User) が、ほぼ、同じになる。一つの CPU が全力で合計を計算した結果である。

スレッド数が 1 から 2 に増えた時は経過時間が半分になった。合計の計算時間に対応するユーザ CPU 時間は一定である。使用したコンピュータが持つ二つのコア^{*14}が必要なユーザ時間を手分けして実行するので、経過時間は半分で済む。二つのスレッドが真に並列実行された。

スレッドの数が 2~4 に増加する間は経過時間が少し短くなる。しかしユーザ CPU 時間が増加している。必要な計算時間は一定のはずなので、長い CPU 時間を必要とするのは CPU の性能が悪化したためと考えられる。

CPU の性能が悪くなったように見えるのは、ハイパースレッディング・テクノロジー [39] により、コアの数が倍 (四個) あるように見せかけているためである。ハイパースレッディング・テクノロジーは、単一スレッドを実行する場合は遊んでしまうコア内のユニットを、二つのスレッドを同時に実行することで効率よく使用する技術である。見かけ上コアの数が二倍になるが合計の性能は二倍には達しないので、コアあたりの性能が下がったように見える。

スレッド数を 4 以上にすると、(見かけ上の) 四つのコア全てが常時使用されるので、経過時間、ユーザ時間の合計のどちらも一定になる。

^{*12} 実行時間が短すぎて比較し難いので、プログラムの 14 行から 18 行を 10 万回繰り返すように改造した上で計測した。

^{*13} 計測に使用したコンピュータは macOS High Sierra をインストールした MacBook Pro (Retaina, 13-inch, Mid 2014, 2.8GHz Inte Core i5) である。C 言語コンパイラは Apple LLVM version 7.0.0 (clang-700.0.72) を使用した。

^{*14} 従来の CPU のこと。

参考文献

- [1] ウキペディア, OS/360, <https://ja.wikipedia.org/wiki/OS/360> (2017.10.03 閲覧)
- [2] ウキペディア, MVS, https://ja.wikipedia.org/wiki/Multiple_Virtual_Storage (2017.10.03 閲覧)
- [3] ウキペディア, OS/390, <https://ja.wikipedia.org/wiki/OS/390> (2017.10.03 閲覧)
- [4] ウキペディア, z/OS, <https://ja.wikipedia.org/wiki/Z/OS> (2017.10.03 閲覧)
- [5] ウキペディア, UNIX (「UNIX および UNIX 系システムの系統図」を含む), <https://ja.wikipedia.org/wiki/UNIX> (2017.10.03 閲覧)
- [6] ウキペディア, Solaris, <https://ja.wikipedia.org/wiki/Solaris> (2017.10.03 閲覧)
- [7] ウキペディア, AIX, <https://ja.wikipedia.org/wiki/AIX> (2017.10.03 閲覧)
- [8] ウキペディア, Mach, <https://ja.wikipedia.org/wiki/Mach> (2017.10.03 閲覧)
- [9] ウキペディア, BSD の子孫, <https://ja.wikipedia.org/wiki/BSD%E3%81%AE%E5%AD%90%E5%AD%AB> (2017.10.03 閲覧)
- [10] ウキペディア, BSD, <https://ja.wikipedia.org/wiki/BSD> (2017.10.04 閲覧)
- [11] ウキペディア, 386BSD, <https://ja.wikipedia.org/wiki/386BSD> (2017.10.04 閲覧)
- [12] ウキペディア, FreeBSD, <https://ja.wikipedia.org/wiki/FreeBSD> (2017.10.03 閲覧)
- [13] ウキペディア, FreeNAS, <https://ja.wikipedia.org/wiki/FreeNAS> (2017.10.03 閲覧)
- [14] ウキペディア, NEXTSTEP, <https://ja.wikipedia.org/wiki/NEXTSTEP> (2017.10.03 閲覧)
- [15] ウキペディア, Classic Mac OS, https://ja.wikipedia.org/wiki/Classic_Mac_OS (2017.10.03 閲覧)
- [16] ウキペディア, ダイナブック, <https://ja.wikipedia.org/wiki/ダイナブック> (2017.10.03 閲覧)
- [17] ウキペディア, macOS, <https://ja.wikipedia.org/wiki/MacOS> (2017.10.03 閲覧)
- [18] ウキペディア, iOS (アップル), [https://ja.wikipedia.org/wiki/IOS_\(アップル\)](https://ja.wikipedia.org/wiki/IOS_(アップル)) (2017.10.03 閲覧)
- [19] ウキペディア, Linux, <https://ja.wikipedia.org/wiki/Linux> (2017.10.03 閲覧)
- [20] ウキペディア, Andriod, <https://ja.wikipedia.org/wiki/Android> (2017.10.03 閲覧)
- [21] ウキペディア, MS-DOS, <https://ja.wikipedia.org/wiki/MS-DOS> (2017.10.03 閲覧)
- [22] ウキペディア, Microsoft Windows (「Windows ファミリー系統図」含む), https://ja.wikipedia.org/wiki/Microsoft_Windows (2017.10.03 閲覧)
- [23] ウキペディア, IBM PC, https://ja.wikipedia.org/wiki/IBM_PC (2017.10.04 閲覧)
- [24] ウキペディア, UNIX System V, https://ja.wikipedia.org/wiki/UNIX_System_V (2017.10.04 閲覧)
- [25] 重村哲至, 情報電子工学科電算機室における PC-UNIX の歴史, <http://www2.tokuyama.ac.jp/giga/Sigemura/Public/IeNet/history.html> (2017.10.03 閲覧)
- [26] Linux kernel release 1.0, <https://www.kernel.org/pub/linux/kernel/v1.0/linux-1.0.tar.gz> (2017.10.04)
- [27] Andrew S. Tanenbaum, Herbert Bos : “The Third Generaton(1965–1980):ICs and Multiproguramming”, Modern Operating Systems (4th Edition), pp.9-14, Pearson Education,Inc (2014).
- [28] Andrew S. Tanenbaum, Herbert Bos : “The Fourth Generation(1980–Present):Personal Computers”, Modern Operating Systems (4th Edition), pp.15–19, Pearson Education,Inc (2014).
- [29] Alan C. Kay : “A Personal Computer for Children of All Ages”, Proceeding ACM '72 Proceedings of

- the ACM annual conference - Volume 1 Article No 1 (1972).
- [30] アラン・ケイ：すべての年齢の「子供たち」のためのパーソナルコンピュータ，阿部和広，小学生からはじめるわくわくプログラミング，pp.130–141，日経 BP 社 (2013).
 - [31] アラン・ケイ：Dynabook とは何か？「すべての年齢の「子供たち」のためのパーソナルコンピュータ」の後日談，阿部和広，小学生からはじめるわくわくプログラミング，pp.142–149，日経 BP 社 (2013).
 - [32] 師尾 潤 他：スーパーコンピュータ「京」のオペレーティングシステム，<http://img.jp.fujitsu.com/downloads/jp/jmag/vol63-3/paper07.pdf> (2017.10.03 閲覧)，富士通 (2012).
 - [33] Marshall Kirk McKusick, George V. Neville-Neil, Robert N. M. Watson : The Zettabyte Filesystem, The Design and Implementation of the FreeBSD Operating System Second Edition, Pearson Education, Inc (2015).
 - [34] Andrew S. Tanenbaum, Herbert Bos : “INTRODUCTION”, Modern Operating Systems (4th Edition), pp.1-3, Pearson Education, Inc (2014).
 - [35] Andrew S. Tanenbaum, Herbert Bos : “VIRTUALIZATION AND THE CLOUD”, Modern Operating Systems (4th Edition), pp.471-516, Pearson Education, Inc (2014).
 - [36] ヴィエムウェア株式会社：「VMware 徹底入門 第 3 版」，廣済堂 (2012).
 - [37] 仮想ハードディスクイメージのダウンロード，<https://www.ubuntulinux.jp/download/ja-remix-vhd> (2017.10.19 閲覧)，Ubuntu Japanese Team (2012).
 - [38] Andrew S. Tanenbaum, Herbert Bos : “Thread Usage”，Modern Operating Systems (4th Edition), pp.97-102, Pearson Education, Inc (2014).
 - [39] ウキペディア，ハイパースレッディング・テクノロジー，<https://ja.wikipedia.org/wiki/%E3%83%8F%E3%82%A4%E3%83%91%E3%83%BC%E3%82%B9%E3%83%AC%E3%83%83%E3%83%87%E3%82%A3%E3%83%B3%E3%82%B0%E3%83%BB%E3%83%86%E3%82%AF%E3%83%8E%E3%83%AD%E3%82%B8%E3%83%BC> (2017.11.02 閲覧)

オペレーティングシステム Ver. 0.0.0

発行年月 2017年10月 Ver.0.0.0

発 行 独立行政法人国立高等専門学校機構
徳山工業高等専門学校
情報電子工学科 重村哲至
〒745-8585 山口県周南市学園台
sigemura@tokuyama.ac.jp