オペレーティングシステム
第３章 CPU の仮想化

https://github.com/tctsigemura/OSTextBook

時分割多重による CPU の仮想化

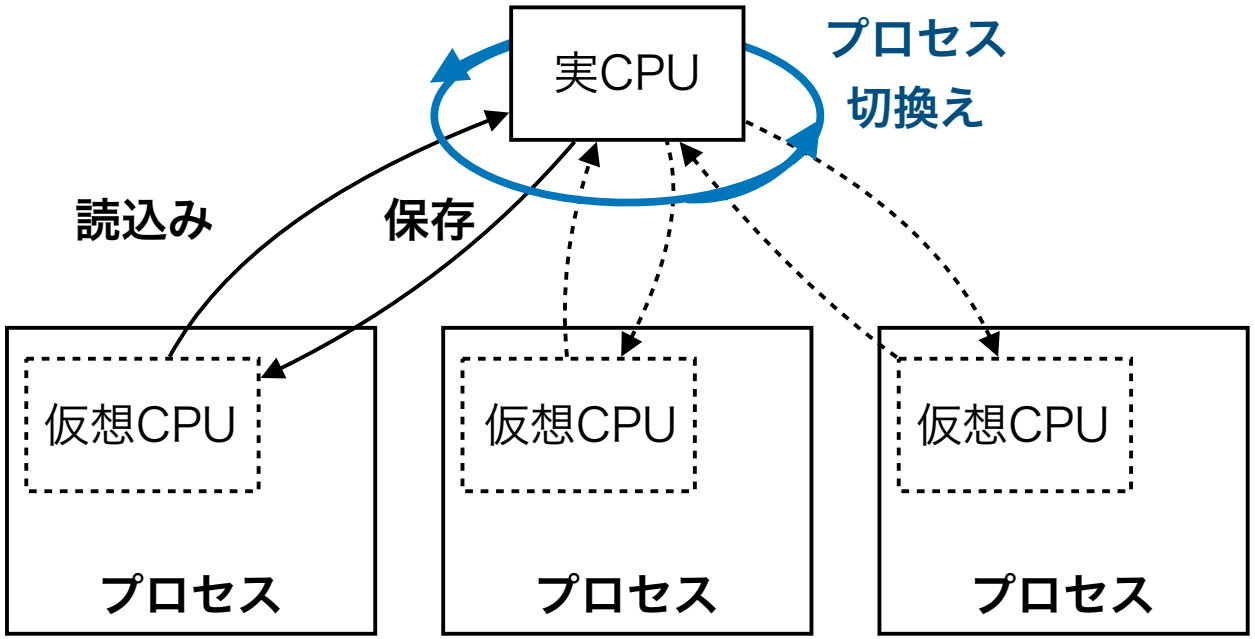

- 時分割多重：CPU が実行するプロセスを次々切換える。
- コンテキストスイッチ：CPU が実行するプロセスを切換えること。
- ディスパッチ：プロセスに CPU を割り付ける。(実行開始)
- ディスパッチャ：ディスパッチするプログラムのこと。

CPU の構造（参考）

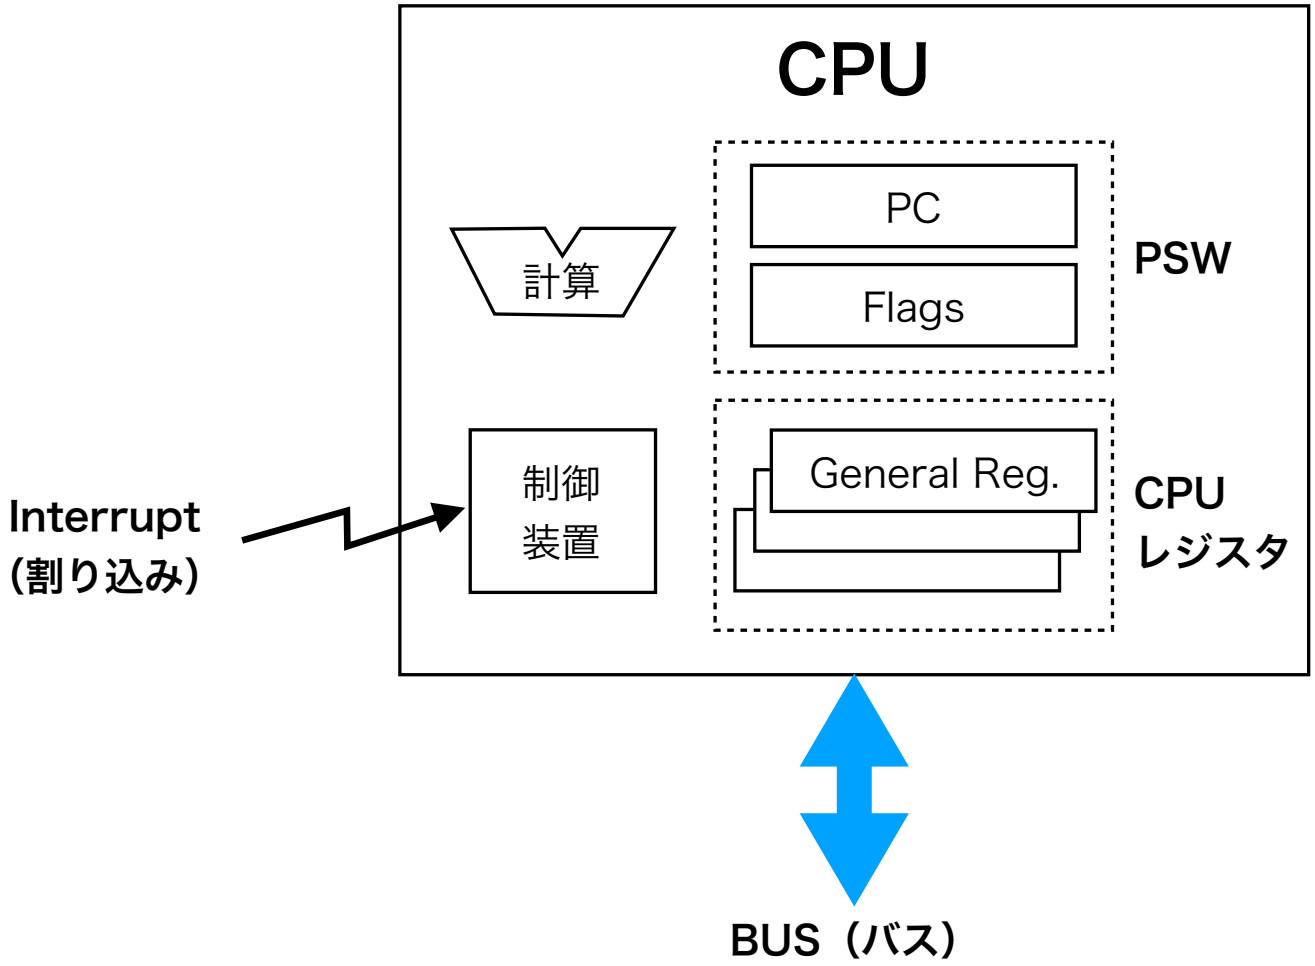

- コンテキスト ＝ PSW + CPU レジスタ
- コンテキストを保存・ロードして次のプロセスに
- コンテキストスイッチ

プロセスの構造（参考）

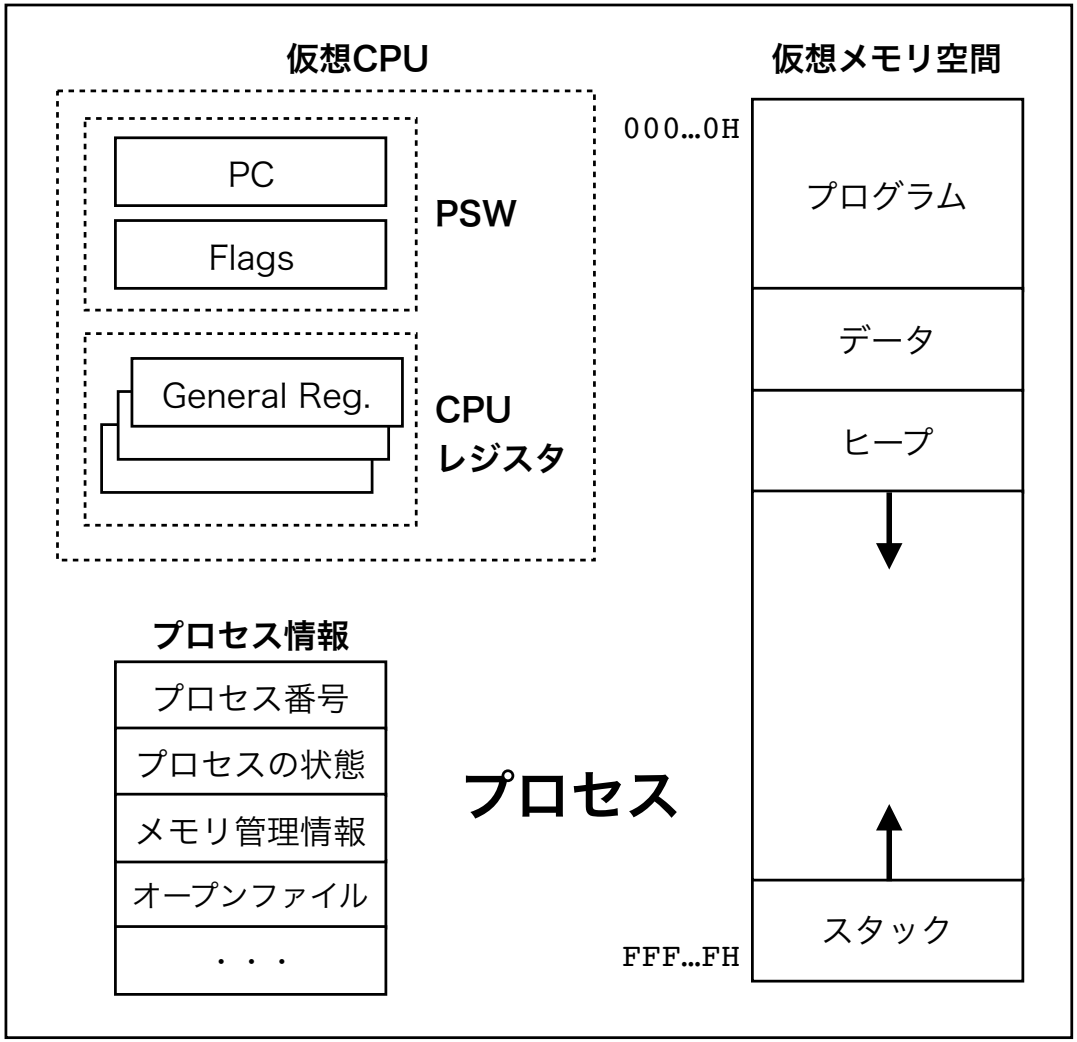

- 仮想 CPU にコンテキストを保存

プロセスの状態遷移

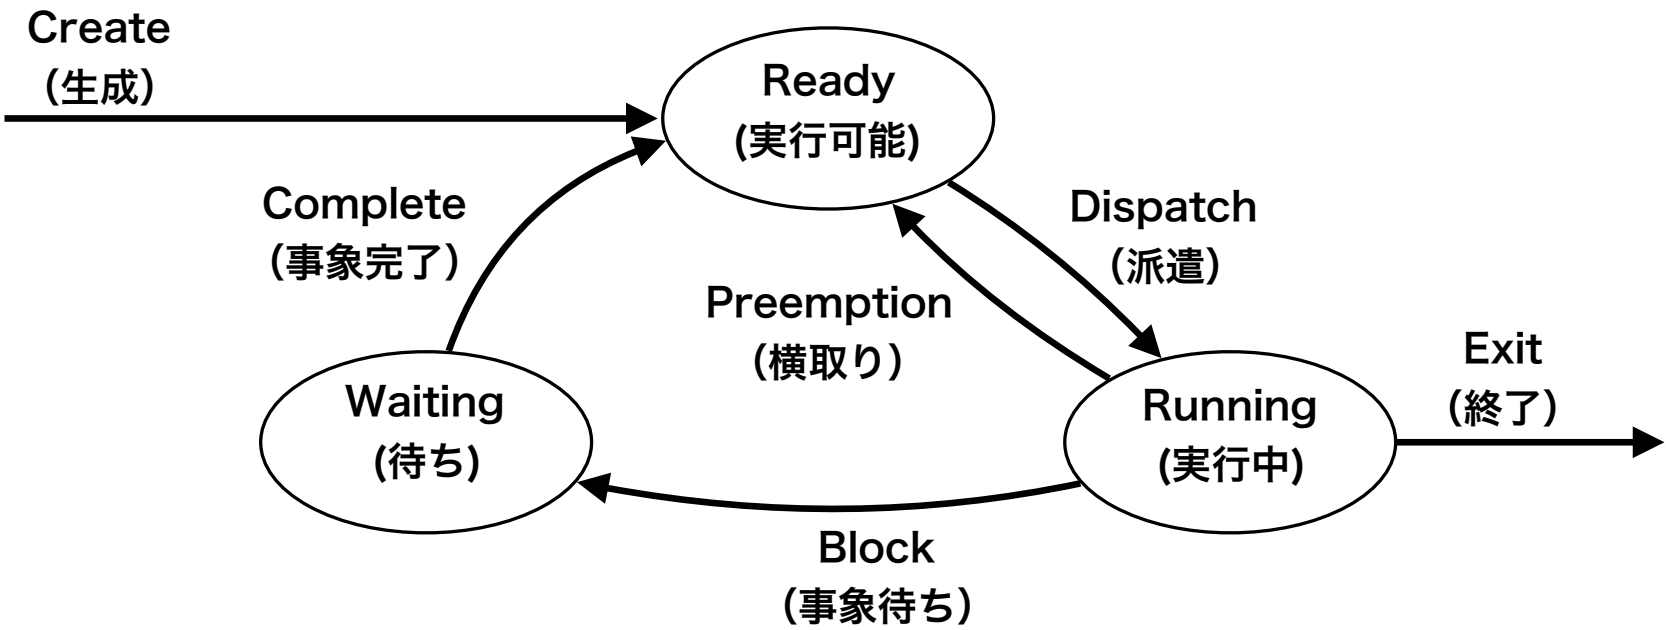

- 基本的な三つの状態
- 六つの状態遷移

プロセスの切換えの原因

- イベント
  プロセス自ら「システムコールを発行する」Block する
  他のプロセスから「**干渉**を受け」Block する
  他のプロセスから「**干渉**を受け」Complete する

- タイムスライシング
  クオンタムタイムを使い切ったプロセスは Preemption する

プロセスの切換え手順

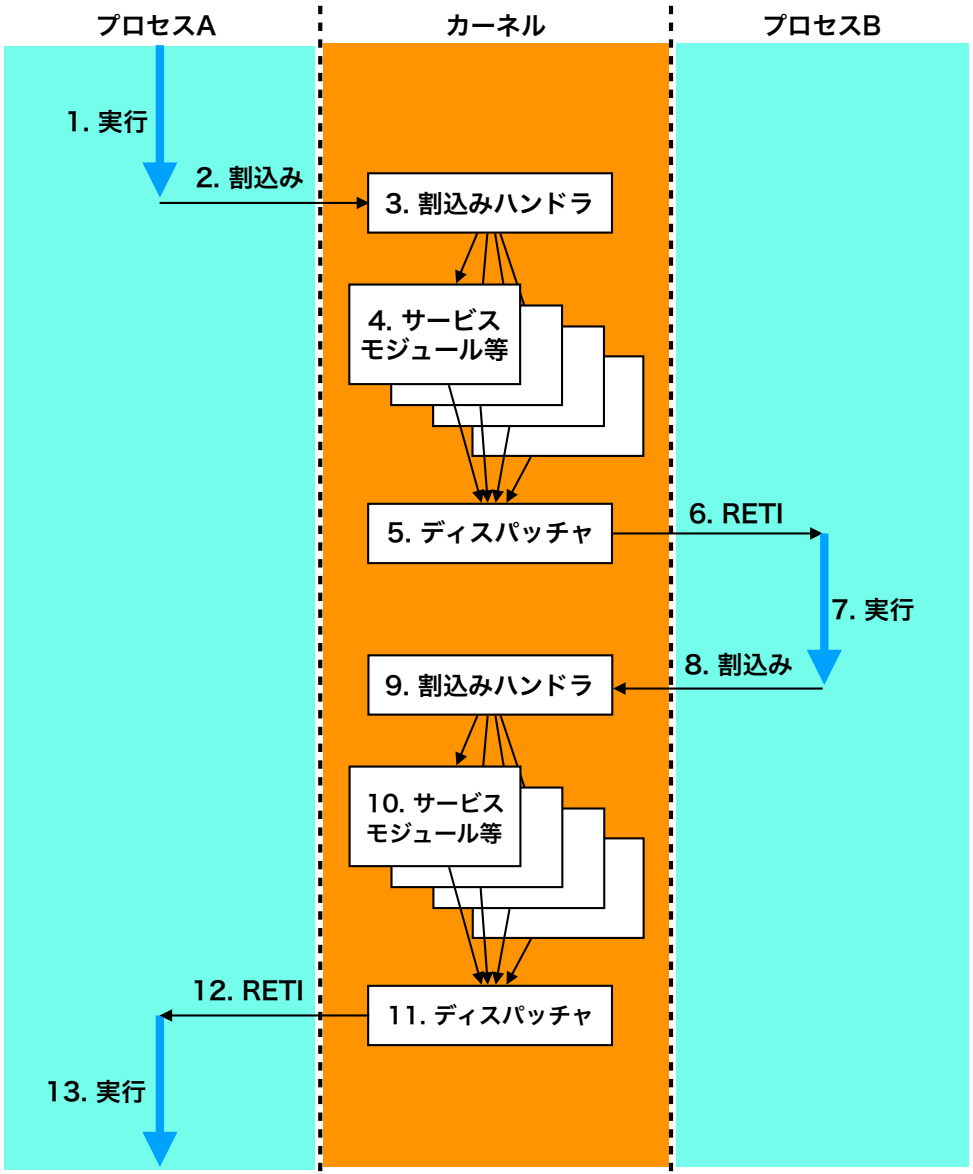
プロセスA
カーネル
プロセスB
1. 実行
2. 割込み
3. 割込みハンドラ
4. サービス
モジュール等
5. ディスパッチャ
6. RETI
7. 実行
8. 割込み
9. 割込みハンドラ
10. サービス
モジュール等
11. ディスパッチャ
12. RETI
13. 実行

オペレーティングシステムの構造（参考）

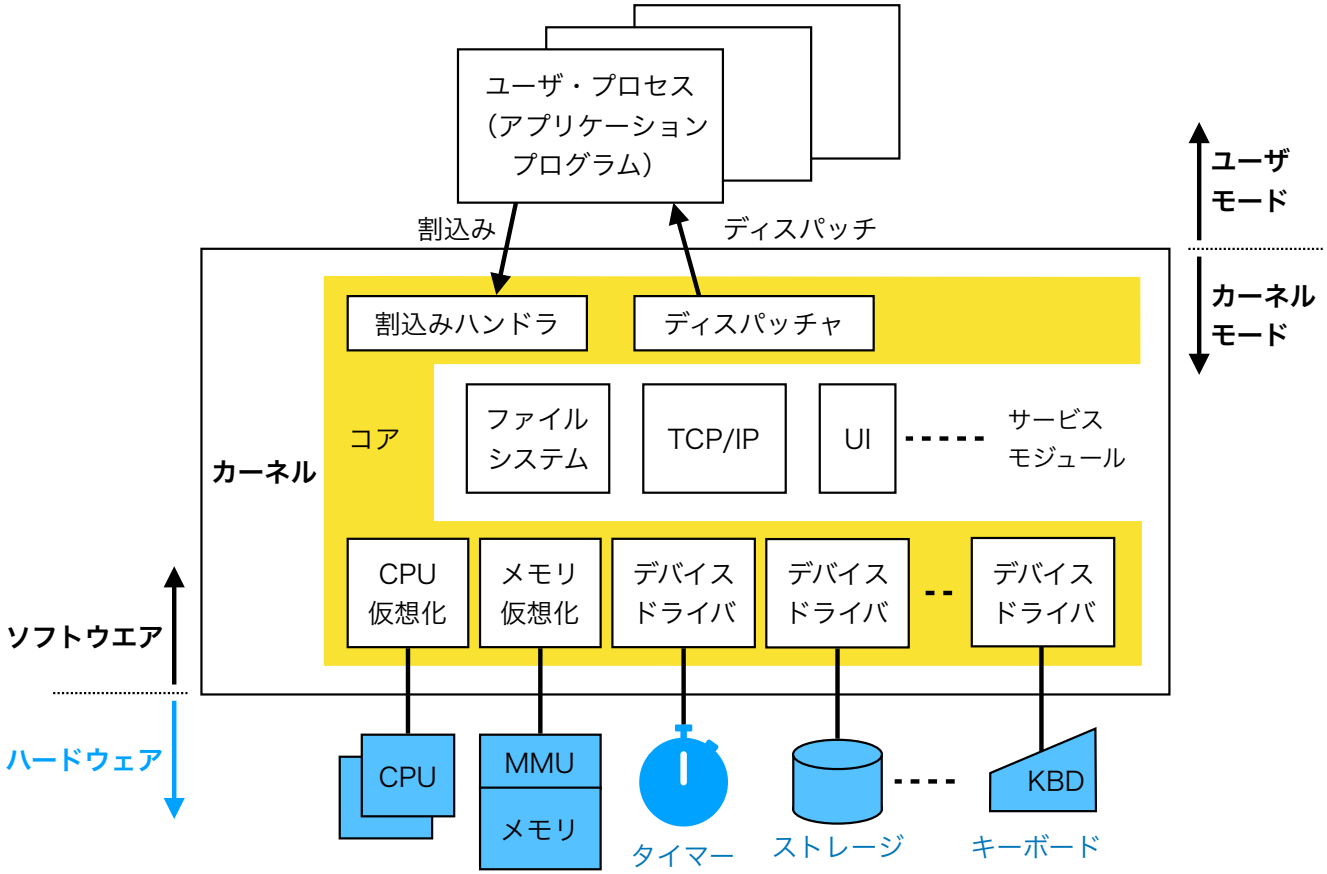

- 割込みハンドラ
- サービスモジュール
- ディスパッチャ

プロセスの切換えの例

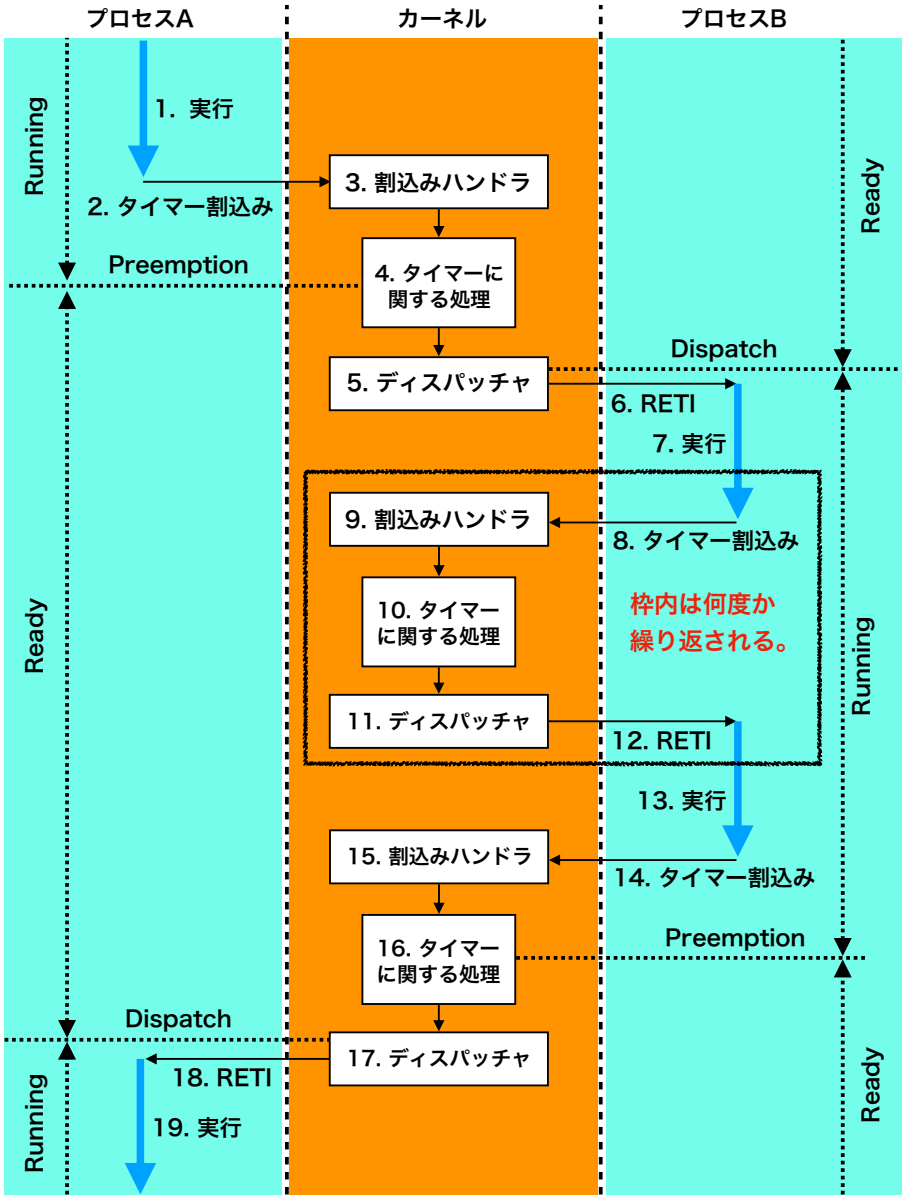
プロセスA
カーネル
プロセスB
Running
1. 実行
2. タイマー割込み
3. 割込みハンドラ
Ready
Preemption
4. タイマーに関する処理
Dispatch
5. ディスパッチャ
6. RETI
7. 実行
9. 割込みハンドラ
8. タイマー割込み
10. タイマーに関する処理
枠内は何度か繰り返される。
11. ディスパッチャ
12. RETI
Running
13. 実行
15. 割込みハンドラ
14. タイマー割込み
16. タイマーに関する処理
Preemption
Ready
Dispatch
17. ディスパッチャ
18. RETI
19. 実行
Running
Ready

PCB（Process Control Block）

- プロセスを表現するカーネル内データ構造
- プロセス毎に存在する
- カーネル内のプロセステーブルに格納される

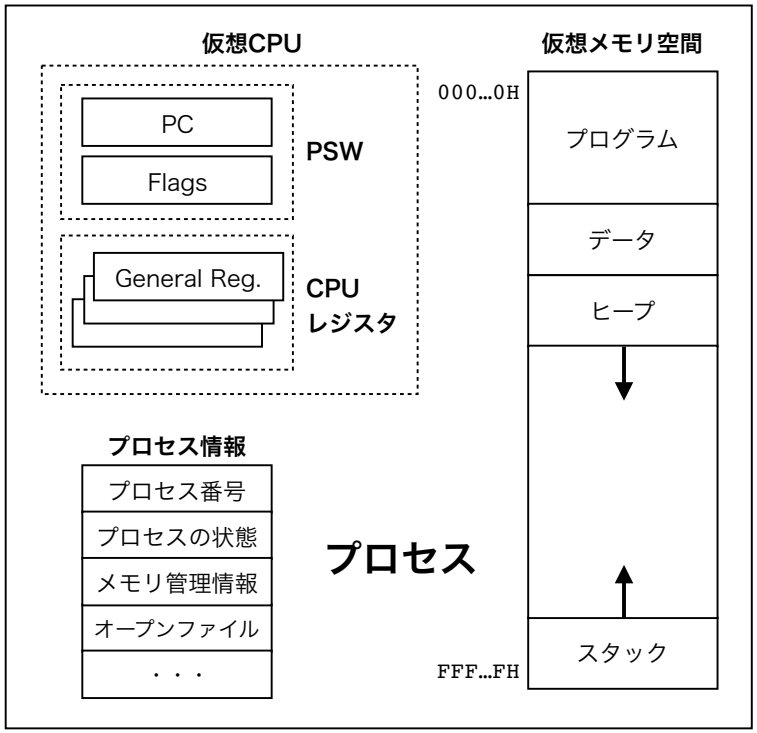

PCB の内容

- 仮想 CPU
- プロセス番号
- 状態（Running，Waiting，Ready 等）
- 優先度
- 統計情報（CPU 利用時間等）
- 次回のアラーム時刻
- 親プロセス
- 子プロセス一覧
- シグナルハンドリング
- 使用中のメモリ
- オープン中のファイル
- カレントディレクトリ
- プロセス所有者のユーザ番号
- PCB のリストを作るためのポインタ

PCB のリスト

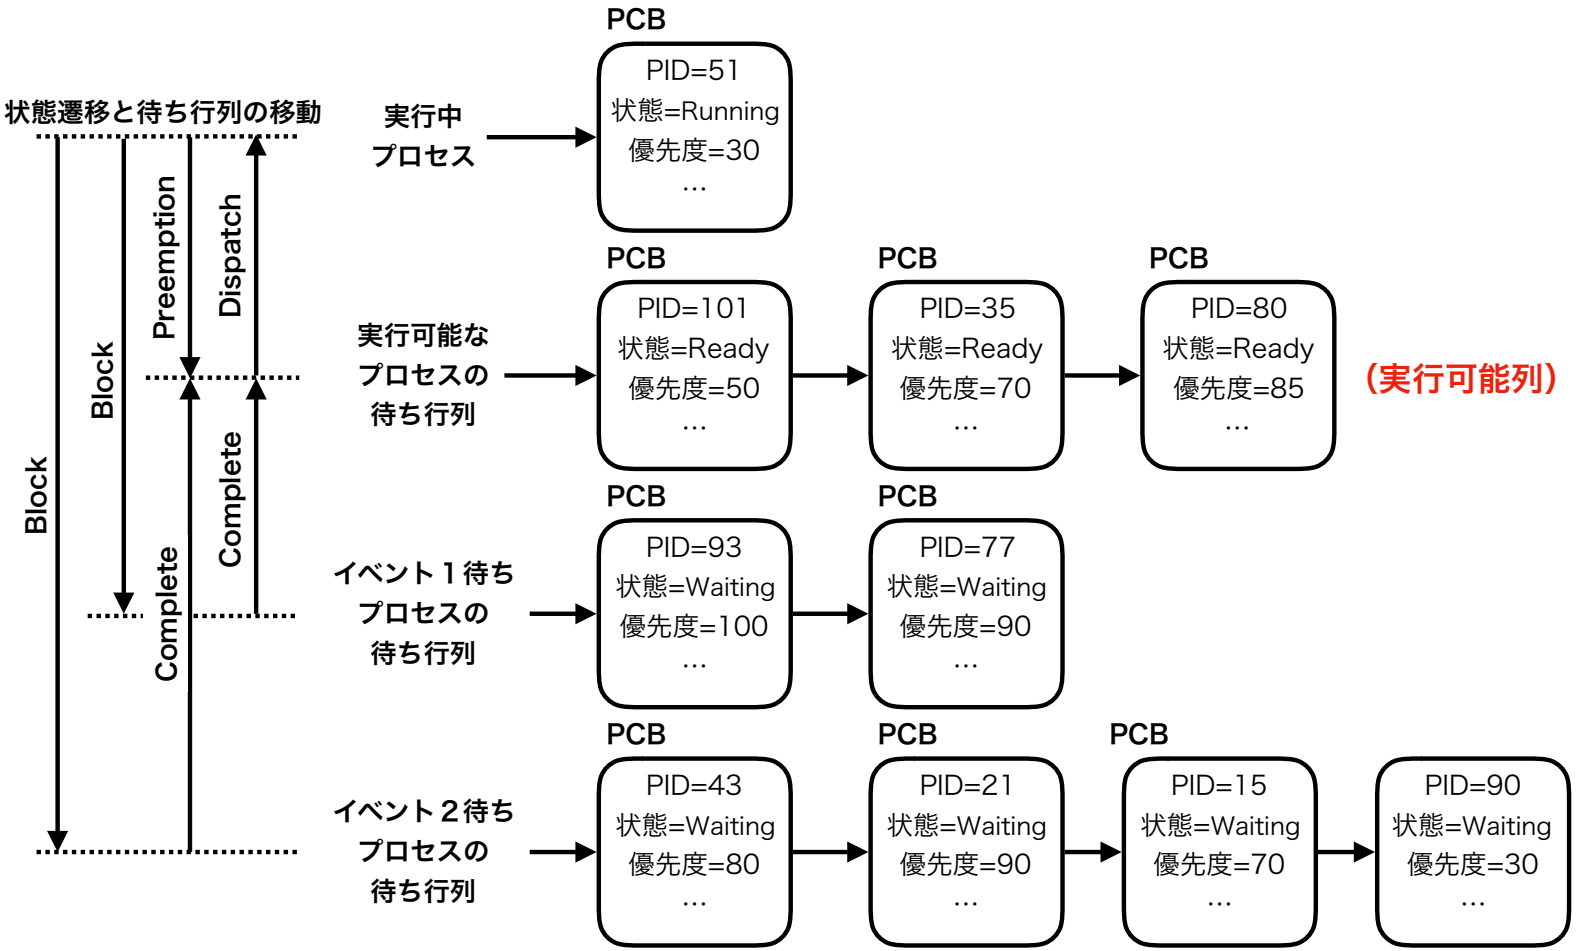

- Ready 状態 PCB のリスト ＝ 実行可能列（優先順位順にソート）
- イベント毎の Waiting 状態 PCB のリスト ＝ イベント待ち行列

TacOS の CPU 仮想化（第１９章）

TacOS の PCB

- 仮想 CPU（sp）
- プロセス番号（pid）
- 状態 (stat)
- 優先度（nice, enice）
- プロセステーブルのインデクス（idx）
- イベント用カウンタとセマフォ (evtCnt，evtSem)
- プロセスのアドレス空間（memBase，memLen）
- プロセスの親子関係の情報（parent，exitStat）
- オープン中のファイル一覧（fds[]）
- PCB リストの管理（prev，next）
- スタックオーバーフローの検知（magic）

TacOS の PCB（前半）

```
// ------------------------------ プロセス関連 ------------------------------
#define PRC_MAX 10          // プロセスは最大 10 個
#define P_KERN_STKSIZ 200 // プロセス毎のカーネルスタックのサイズ
#define P_LOW_PRI 30000    // プロセスの最低優先度
#define P_RUN     1         // プロセスは実行可能または実行中
#define P_WAIT    2         // プロセスは待ち状態
#define P_ZOMBIE 3          // プロセスは実行終了
#define P_MAGIC  0xabcd     // スタックオーバーフロー検知に使用
#define P_FILE_MAX 4        // プロセスがオープンできるファイルの最大数

// プロセスコントロールブロック (PCB)
//    優先度は値が小さいほど優先度が高い
1 struct PCB {                  // PCB を表す構造体
2   int sp;                     // コンテキスト (他の CPU レジスタと PSW は
3                               //                  プロセスのカーネルスタックに置く)
4   int pid;                    // プロセス番号
5   int stat;                   // プロセスの状態
6   int nice;                   // プロセスの本来優先度
7   int enice;                  // プロセスの実質優先度 (将来用)
8   int idx;                    // この PCB のプロセステーブル上のインデクス
```

TacOS の PCB（後半）

```
10    // プロセスのイベント用セマフォ
11    int evtCnt;                // カウンタ (>0:sleep 中, ==-1:wait 中, ==0:未使用)
12    int evtSem;                // イベント用セマフォの番号
13
14    // プロセスのアドレス空間 (text, data, bss, ...)
15    char[] memBase;            // プロセスのメモリ領域のアドレス
16    int memLen;                // プロセスのメモリ領域の長さ
17
18    // プロセスの親子関係の情報
19    PCB parent;                // 親プロセスへのポインタ
20    int exitStat;              // プロセスの終了ステータス
21
22    // オープン中のファイル一覧
23    int[] fds;                 // オープン中のファイル一覧
24
25    // プロセスは重連結環状リストで管理
26    PCB prev;                  // PCB リスト (前へのポインタ)
27    PCB next;                  // PCB リスト (次へのポインタ)
28    int magic;                 // スタックオーバーフローを検知
29  };
```

TacOS の実行可能列

- PCB の双方向環状リスト
- 優先度順にソート（curProc は実行中のプロセス）
- 末尾に idle プロセスが常駐

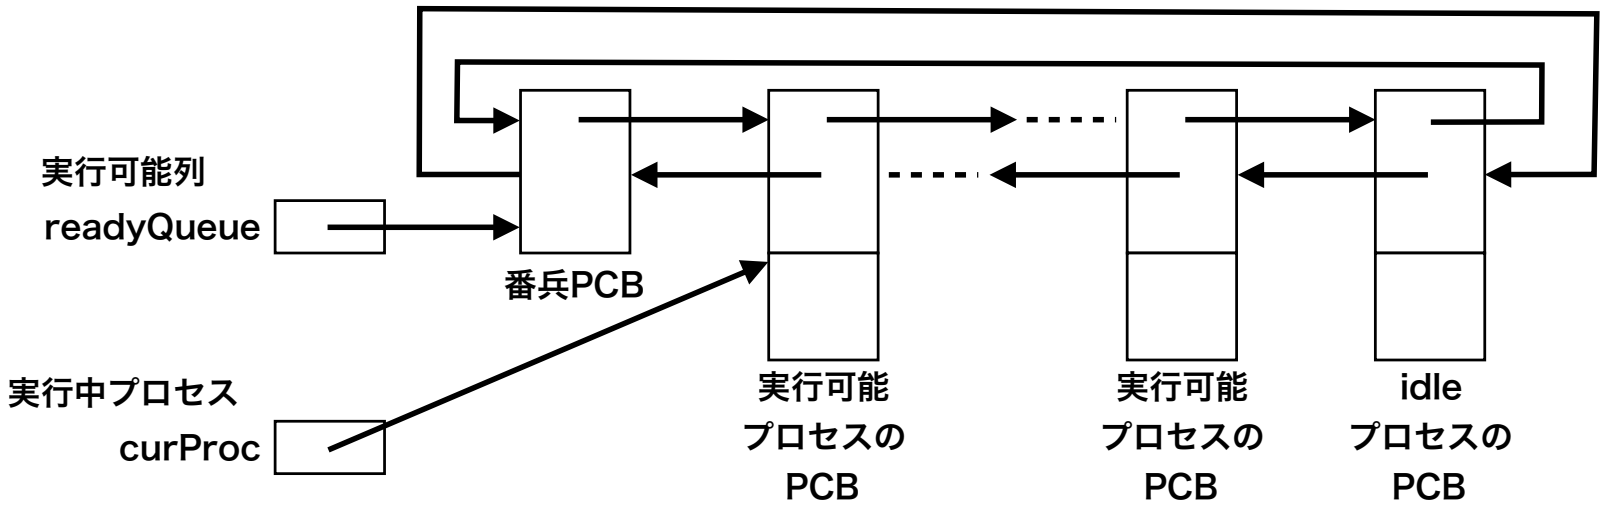

TacOS のメモリ配置

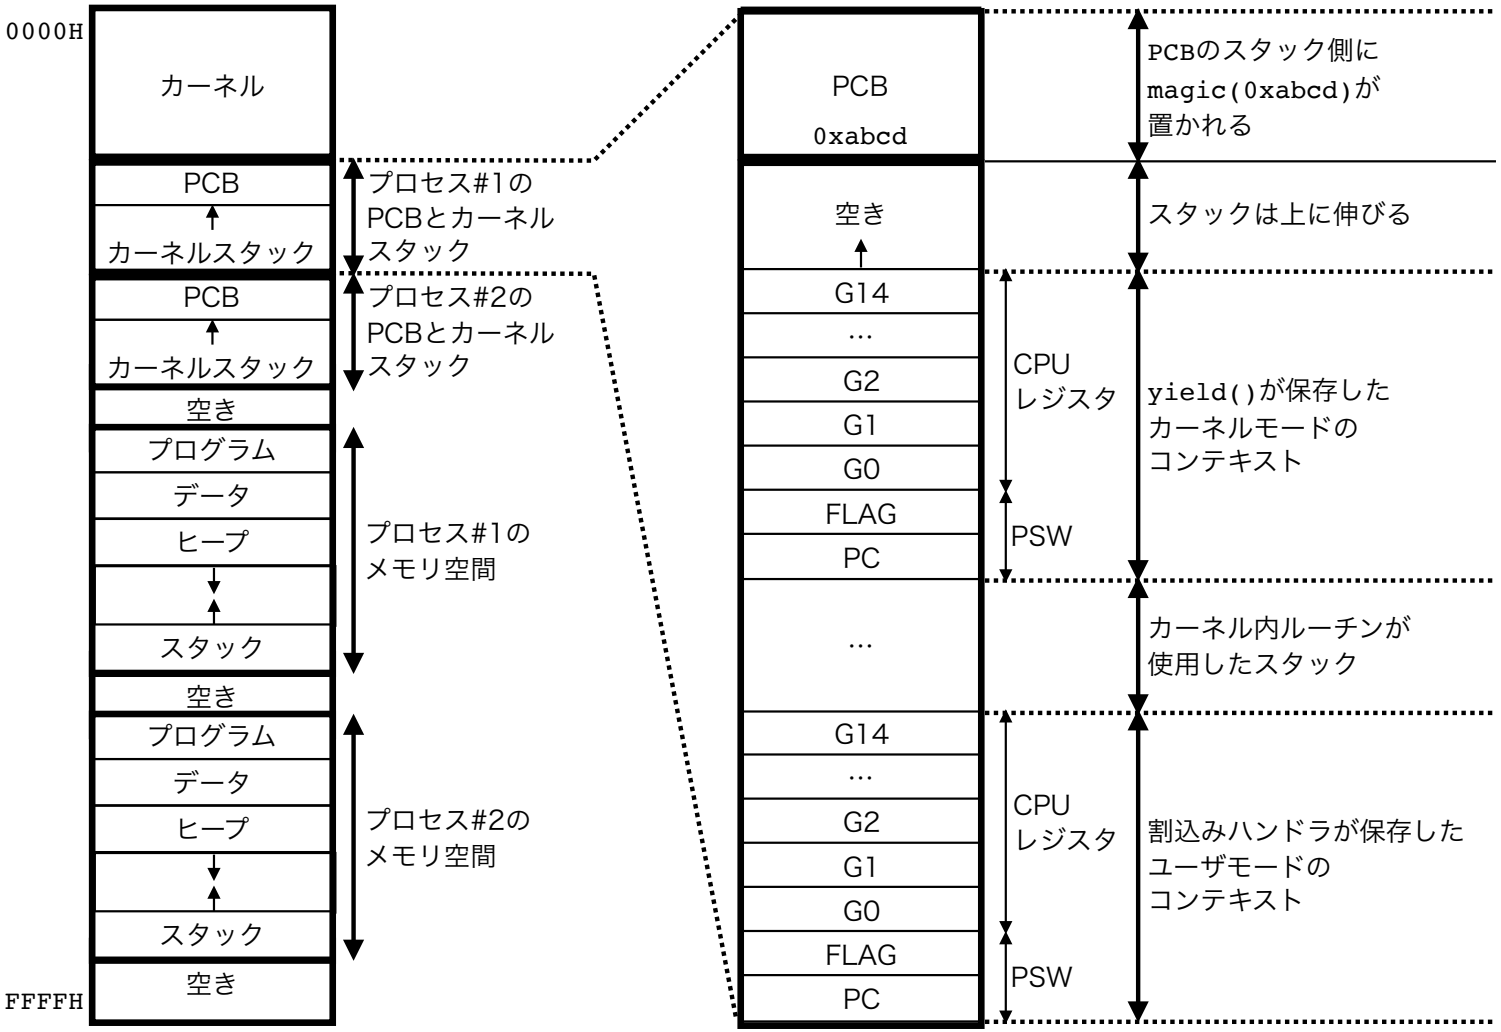

(a) 物理メモリ空間　　(b) PCBとカーネルスタック

TacOS のタイマー管理プログラム

```
3  // タイマー割り込みハンドラ (10ms 毎に割り込みによって起動される)
4  interrupt tmrIntr() {
5    boolean disp = false;                          // ディスパッチの必要性
6
7    // 起きないといけないプロセスを起こしてまわる
8    for (int i=0; i<PRC_MAX; i=i+1) {
9      PCB p = procTbl[i];
10     if (p!=null && p.evtCnt>0) {                 // タイマー稼働中なら
11       int cnt = p.evtCnt - TICK;                 //   残り時間を計算
12       if (cnt<=0) {                              //   時間が来たら
13         cnt = 0;                                 //     タイマーを停止し
14         disp = iSemV(p.evtSem) || disp;          //     プロセスを起こす
15       }
16       p.evtCnt = cnt;
17     }
18   }
19
20   if (disp) yield();                             // 必要ならディスパッチ
21 }
```

TacOS のコンテキスト保存プログラム（yield()）

```
1  _yield
2          ;--- G13(SP) 以外の CPU レジスタと FLAG をカーネルスタックに退避 ---
3          push    g0                  ; FLAG の保存場所を準備する
4          push    g0                  ; G0 を保存
5          ld      g0,flag             ; FLAG を上で準備した位置に保存
6          st      g0,2,sp             ;
7          push    g1                  ; G1 を保存
8          push    g2                  ; G2 を保存
           ...
17         push    g11                 ; G11 を保存
18         push    fp                  ; フレームポインタ (G12) を保存
19         push    usp                 ; ユーザモードスタックポインタ (G14) を保存
20         ;
21         ;------- G13(SP) を PCB に保存 --------------------------
22         ld      g1,_curProc         ; G1 <- curProc
23         st      sp,0,g1             ; [G1+0] は PCB の sp フィールド
24         ;
25         ;------- [curProc の magic フィールド] をチェック ---------
26         ld      g0,30,g1            ; [G1+30] は PCB の magic フィールド
27         cmp     g0,#0xabcd          ; P_MAGIC と比較、一致しなければ
28         jnz     .stkOverFlow        ; カーネルスタックがオーバーフローしている
```

TacOS のコンテスト復旧プログラム（dispatch()）

```
1  _dispatch
2          ;-------- 次に実行するプロセスの G13(SP) を復元 ----------
3          ld      g0,_readyQueue  ; 実行可能列の番兵のアドレス
4          ld      g0,28,g0        ; [G0+28] は PCB の next フィールド (先頭の PCB)
5          st      g0,_curProc     ; 現在のプロセス (curProc) に設定する
6          ld      sp,0,g0         ; PCB から SP を取り出す
7          ;
8          ;-------- G13(SP) 以外の CPU レジスタを復元 -----------
9          pop     usp             ; ユーザモードスタックポインタ (G14) を復元
10         pop     fp              ; フレームポインタ (G12) を復元
11         pop     g11             ; G11 を復元
12         pop     g10             ; G10 を復元
13         pop     g9              ; G9 を復元

           ...

21         pop     g1              ; G1 を復元
22         pop     g0              ; G0 を復元
23         ;
24         ;------------- PSW(FLAG と PC) を復元 -----------------
25         reti                    ; RETI 命令で一度に POP して復元する
```

スレッド（Thread）

- CPU の仮想化によりマルチプログラミングが可能になった.
- プロセスが並行（Concurrent）に実行できる.
- プロセスは**一つ**の仮想 CPU を持っている.
- プロセスはコンピュータを仮想化したもの.
  - CPU が一つしかないコンピュータを仮想化している.
  - CPU を複数持つ SMP を仮想化するには不十分.
- 一つのプロセスが複数の仮想 CPU をもつモデルを導入する.
- プロセスが処理の流れ**スレッド**を複数持つことができる.

スレッドの役割（1）

マルチプログラミングを用いない Web サーバ

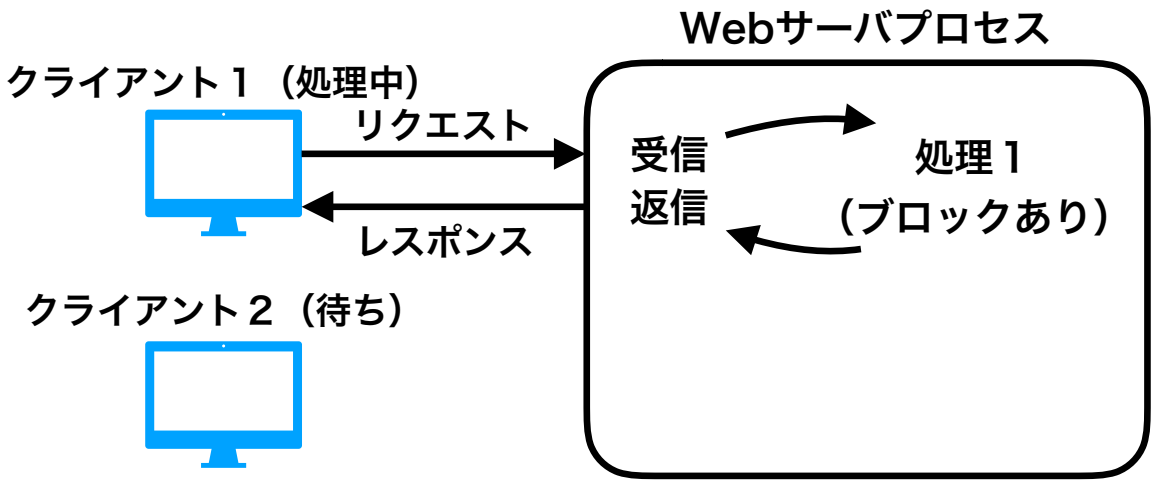

- 処理は順番に処理される.
- 前の処理が終わるまでクライアントは待たされる.

スレッドの役割（2）

マルチプログラミングを用いない Web サーバ

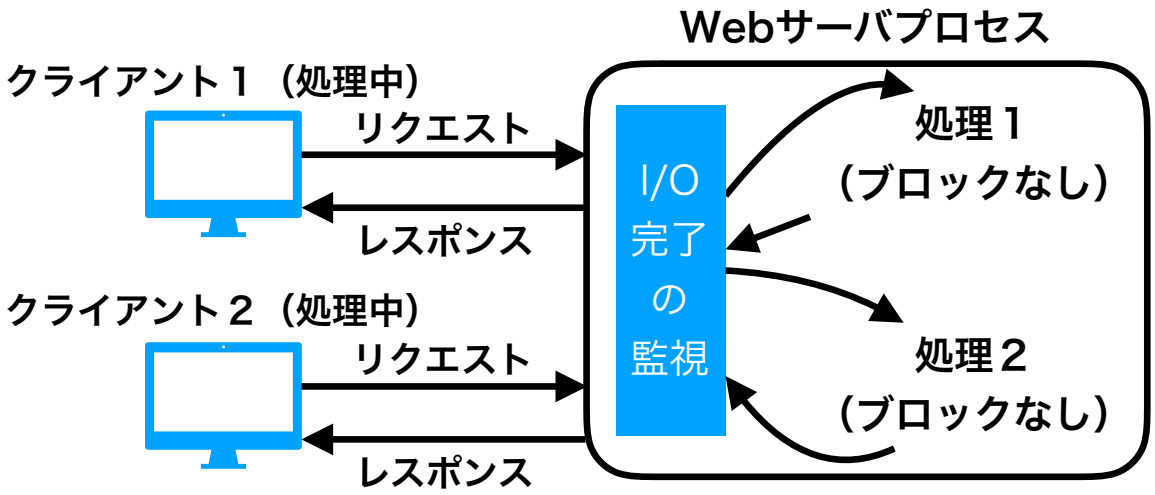

- 工夫すると並列して処理することも可能
- しかし，プログラミングが難しい．

スレッドの役割（3）

マルチプログラミングを用いる Web サーバ（プロセス版）

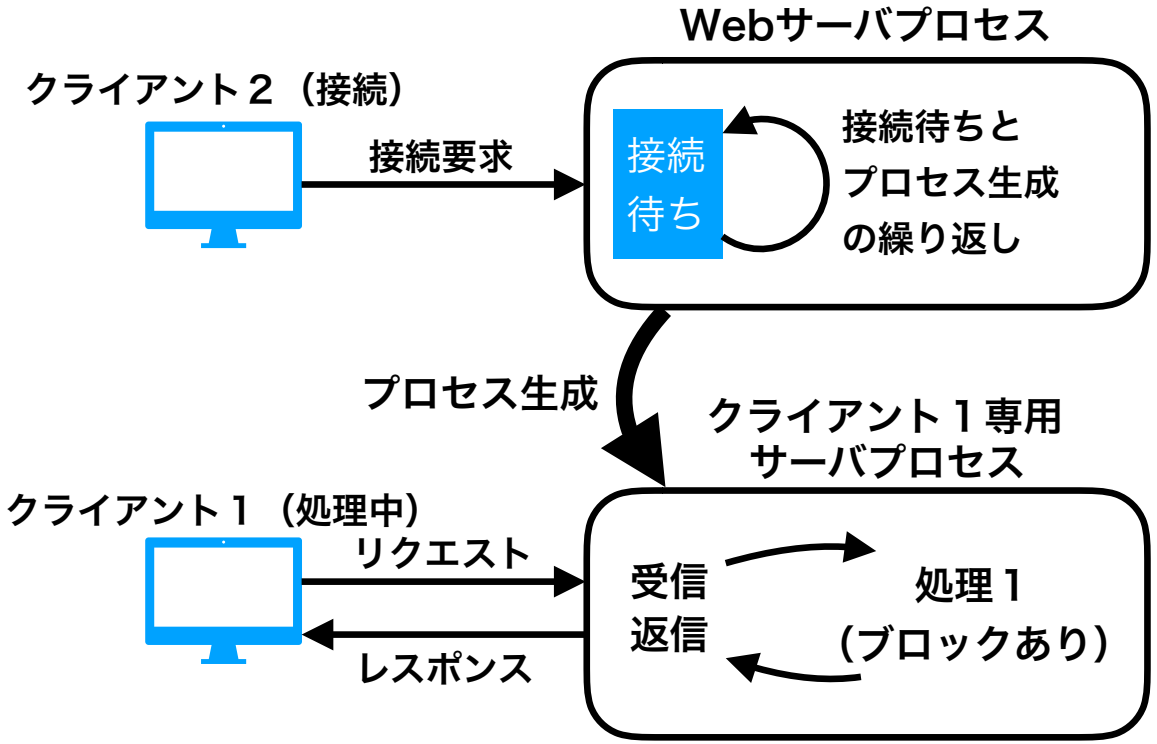

- クライアント毎にプロセスを起動（fork()）する.
- プログラミングは易しい.
- しかし，処理が重い.

スレッドの役割（4）

マルチプログラミングを用いる Web サーバ（スレッド版）

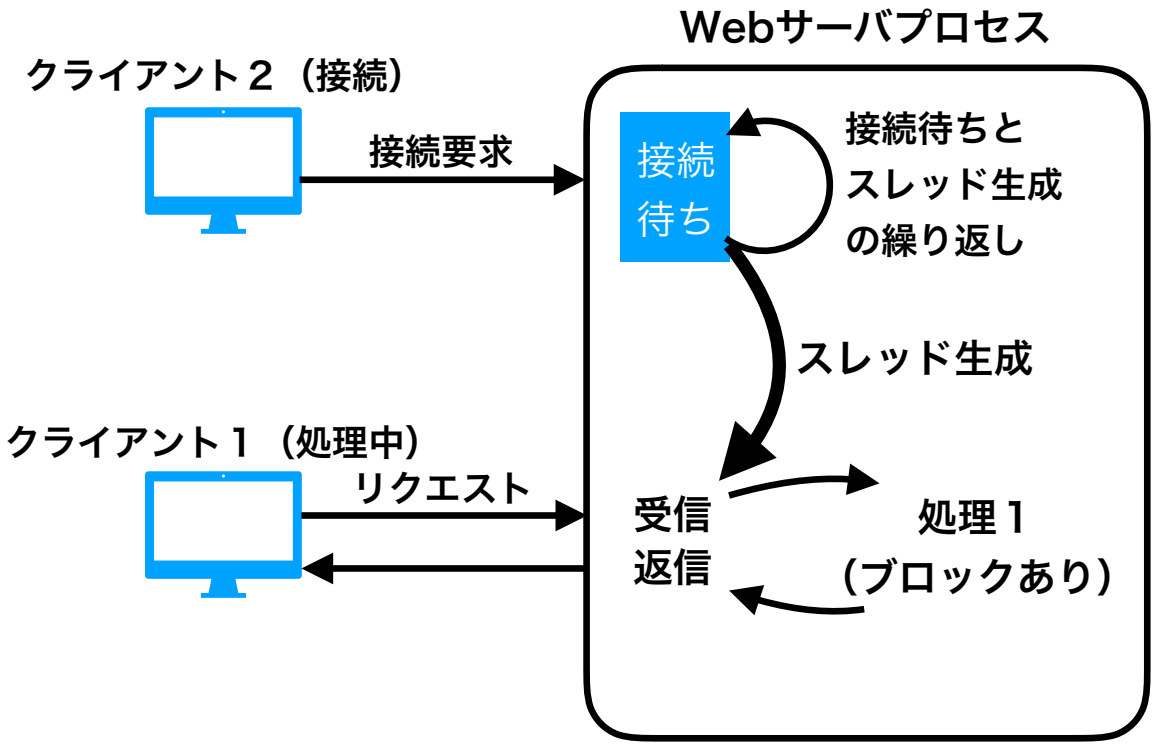

- クライアント毎にスレッドを起動する.
- プロセスの起動より 10〜100 倍速い.
- スレッド間は情報を共有しやすい.
- プログラミングは少し難しい.

スレッドの形式（1）–カーネルスレッド–

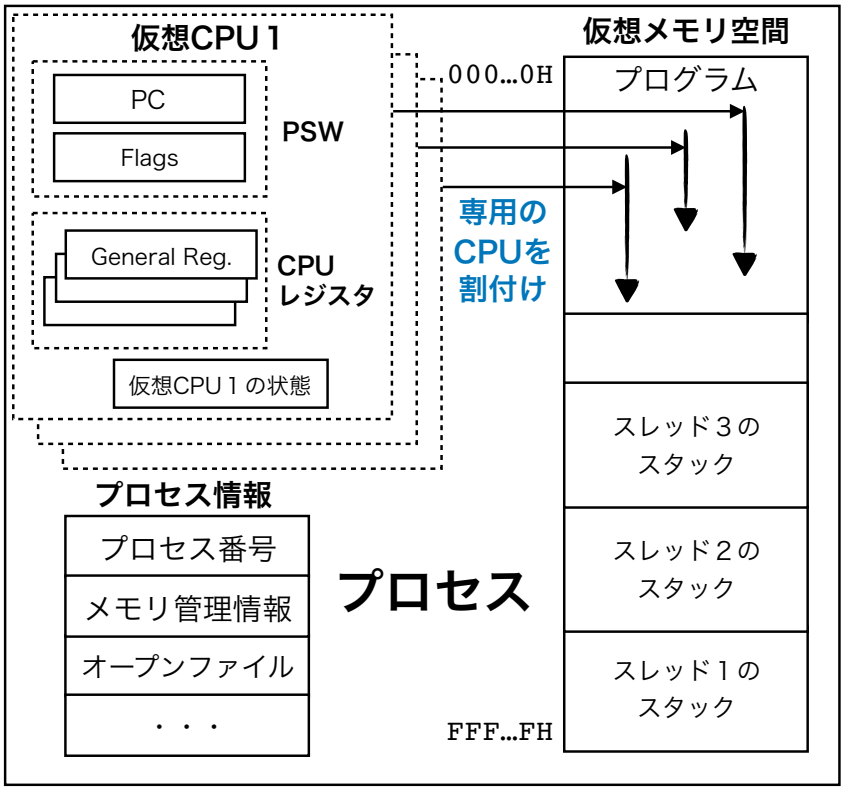

- プロセスが複数の仮想 CPU を持つ.

スレッドの形式（2）–ユーザスレッド–

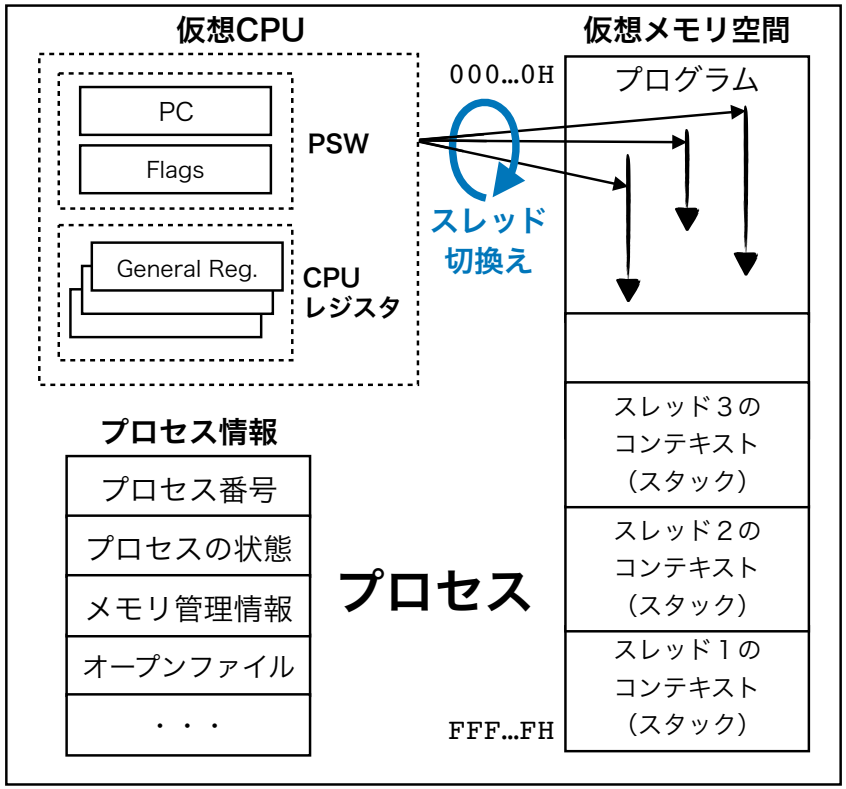

- ユーザプログラム（ライブラリ）の工夫でスレッドを実現する.
- 並行（Parallel）実行はできない.
- どれかのスレッドがブロックすると全スレッドが停止する.

スレッドの形式（3）–スレッドモデル–

上記の 2 方式を組み合わせた 3 種類のスレッドモデルがある.

- *One-to-One Model*
  一つのユーザスレッドを一つのカーネルスレッドで実行する.
- *Many-to-One Model*
  複数のユーザスレッドを一つのカーネルスレッドで実行する.
- *Many-to-Many Model*
  複数のユーザスレッドを複数のカーネルスレッドで実行する.

スレッドの使用例（1）

M 個のスレッドで手分けをして合計を計算する様子
(複数のカーネルスレッド（CPU）で手分けすることで短時間で処理が終わるはず)

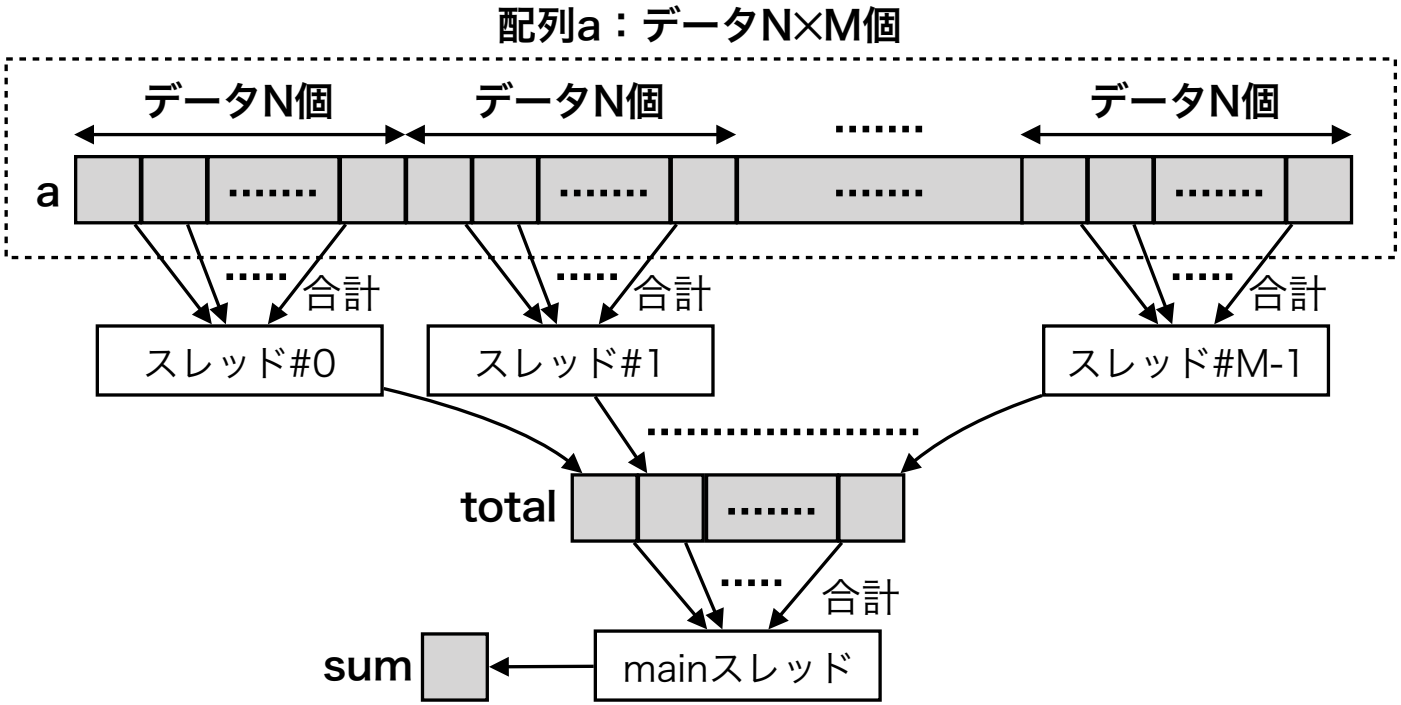

スレッドの使用例（2）

M 個のスレッドで合計を計算するプログラム

```
 1  #include <stdio.h>
 2  #include <stdlib.h>
 3  #include <pthread.h>
 4  #define N 1000                                  // 1スレッドの担当データ数
 5  #define M 10                                    // スレッド数
 6  pthread_t tid[M];                               // M 個のスレッドのスレッド ID
 7  pthread_attr_t attr[M];                         // M 個のスレッドの属性
 8  int a[M*N];                                     // このデータの合計を求める
 9  int total[M];                                   // 各スレッドの求めた部分和
10  typedef struct { int no, min, max; } Args;      // スレッドに渡す引数の型定義
11
12  void *thread(void *arg) {          // 自スレッドの担当部分のデータの合計を求める
13    Args *args = arg;                             // m 番目のスレッド
14    int sum = 0;                                  // 合計を求める変数
15    for (int i=args->min; i<args->max; i++) {     // a[N*m ... (N+1)*m] の
16      sum += a[i];                                //    合計を sum に求める.
17    }
18    total[args->no]=sum;                          // 担当部分の合計を記録
19    return NULL;                                  // スレッドを正常終了する
20  }
```

スレッドの使用例（3）

```
22 int main() {                                  // main スレッドの実行はここから始まる
23   // 擬似的なデータを生成する
24   for (int i=0; i<M*N; i++)                                  // 配列 a   を初期化
25     a[i] = i+1;
26   // M 個のスレッドを起動する
27   for (int m=0; m<M; m++) {                                  // 各スレッドについて
28     Args *p = malloc(sizeof(Args));                          //   引数領域を確保
29     p->no = m;                                               //     m 番目のスレッド
30     p->min = N*m;                                            //     担当範囲下限
31     p->max = N*(m+1);                                        //     担当範囲上限
32     pthread_attr_init(&attr[m]);                             //   アトリビュート初期化
33     pthread_create(&tid[m], &attr[m], thread, p); //   スレッドを生成しスタート
34   }
35   // 各スレッドの終了を待ち, 求めた小計を合算する
36   int sum = 0;
37   for (int m=0; m<M; m++) {                                  // 各スレッドについて
38     pthread_join(tid[m], NULL);                              //   終了を待ち
39     sum += total[m];                                         //   小計を合算する
40   }
41   printf("1+2+␣...␣+%d=%d\n", N*M, sum);
42   return 0;
43 }
```

スレッドの使用例（4）

実行時間の計測結果

	スレッド数 (M)・データ件数 (M*N)									
M	1	2	3	4	5	6	7	8	9	10
N	10,000	5,000	3,333	2,500	2,000	1,666	1,428	1,250	1,111	1,000
M*N	10,000	10,000	9,999	10,000	10,000	9,996	9,996	10,000	9,999	10,000
経過時間 (s)	1.881	0.980	0.657	0.493	0.406	0.339	0.335	0.332	0.319	0.312
ユーザ CPU 時間 (s)	1.879	1.953	1.959	1.958	2.009	2.011	2.244	2.462	2.679	2.846
システム CPU 時間 (s)	0.002	0.002	0.002	0.001	0.001	0.002	0.003	0.003	0.003	0.002

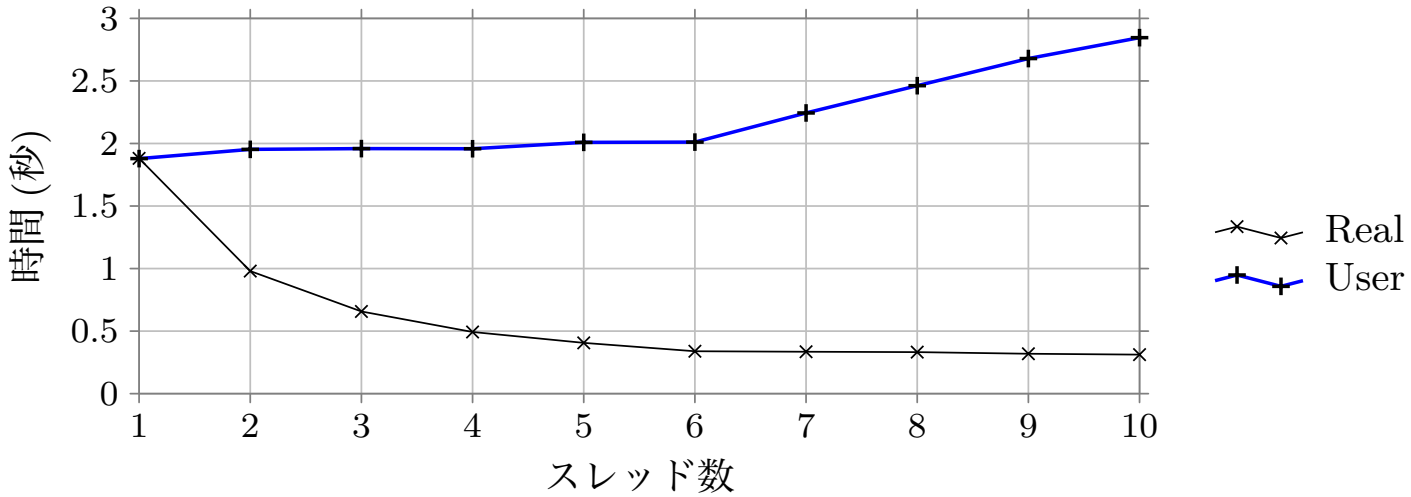

6 コアの Mac Pro で計測
(Hyper-Threading のお陰で 6 コアと 12 コアの中間的な振舞)

練習問題

- 次の言葉の意味を説明しなさい.
  - 時分割多重
  - コンテキストスイッチ
  - Dispatch（ディスパッチ）
  - Preemption（プリエンプション）
  - プロセスの状態
  - プロセスの状態遷移
  - RETI 命令
  - PCB
  - 待ち行列
  - 実行可能列
  - スレッド
  - カーネルスレッド
  - ユーザスレッド
  - One-to-One Model
  - Many-to-One Model
  - Many-to-Many Model
- POSIX スレッドについて調査しなさい.